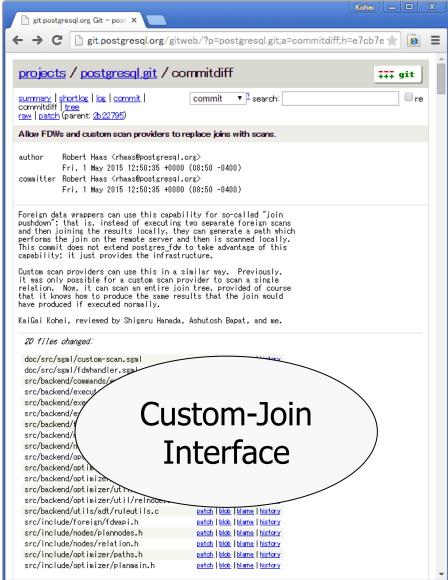


#### v9.5 New Feature





### Custom Scan/Join Interfaceが実現する事

- クエリ実行計画の一部を、拡張モジュール実装の "何か" で置き換える
- 何を置き換える事ができるのか?
  - Scan ... set\_rel\_pathlist\_hook で候補パス追加
  - Join ... set\_join\_pathlist\_hook で候補パス追加
  - Others ... planner\_hookを使ってインジェクションすれば何でもアリ。
    - → 局所最適にならないよう、注意は必要だが…。

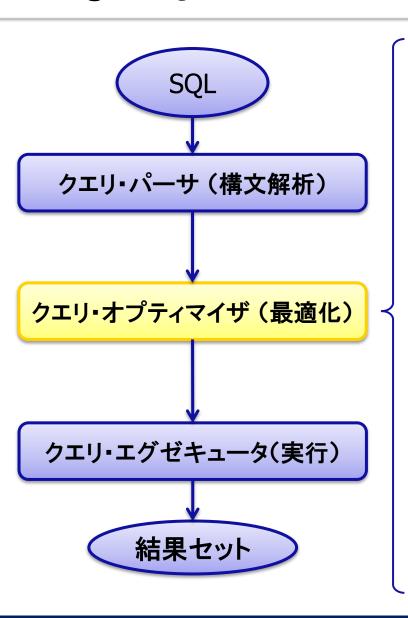
#### 応用例

- GPUアクセラレーションによる全体的なRDBMS性能の底上げ。
  - → PG-Strom (オタワで発表するんでヨロ)
- 特定のテーブル同士のJoinをMaterialized Viewスキャンに透過的に置換え。
- ●特定のテーブルのうち、参照頻度の高い列だけを列指向形式でキャッシュ
- Scan/Joinの中間結果から統計情報を採取。値によるヒストグラム作成。
- .....など

### クエリ実行計画

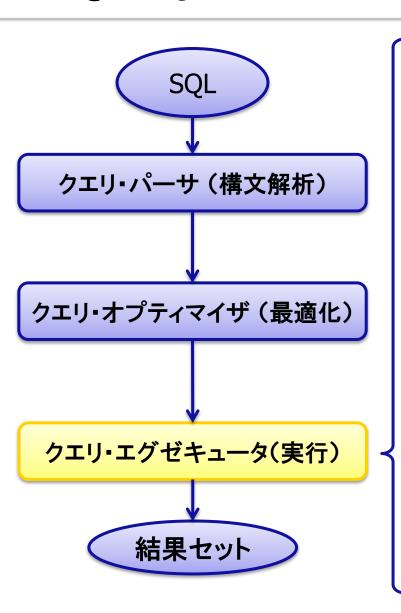
```
postgres=# EXPLAIN SELECT cat, AVG(x)
   FROM to NATURAL JOIN t1 RIGHT JOIN t2 ON t0.aid=t2.bid OR t0.bid=t2.bid
   WHERE atext like '%abc%' GROUP BY cat;
                                QUERY PLAN
HashAggregate (cost=979149.25..979149.58 rows=26 width=12)
Group Key: t0.cat
 -> Nested Loop (cost=834.05..979139.33 rows=1985 width=12)
    Join Filter: ((t0.aid = t2.bid) OR (t0.bid = t2.bid))
    -> Seq Scan on t2 (cost=0.00..734.00 rows=40000 width=4)
    -> Materialize (cost=834.05..281207.82 rows=996 width=20)
       -> Hash Join (cost=834.05..281202.84 rows=996 width=20)
         Hash Cond: (t0.aid = t1.aid)
          -> Seq Scan on t0 (cost=0.00..242858.60 rows=10000060 width=20)
          -> Hash (cost=834.00..834.00 rows=4 width=4)
             -> Seq Scan on t1 (cost=0.00..834.00 rows=4 width=4)
               Filter: (atext ~~ '%abc%'::text)
(12 rows)
```

## PostgreSQL クエリ処理の流れ (1/2)



- リレーションに対する候補パスを列挙
  - Base Relation
  - Join Relation
- プラナーが最も実行コストの小さな パスを選択。
- →全てのテーブルを単一のJoin-Treeに 収めるまで結合順を試行錯誤
- ■実行パスを元に、実行計画を作成

# PostgreSQL クエリ処理の流れ (2/2)



- ExecInitNode
  - 実行ノードの初期化
- ExecProcNode
  - 一行を生成して TupleTableSlot を返す
- ExecEndNode
  - 実行ノードの終了処理
- その他
  - ExecReScan
  - ExecMarkPos (optional)
  - ExecRestrPos (optional)

# Custom Scan/Joinを使うには (1/3)

#### 候補パスを追加する

```
typedef void (*set_rel_pathlist_hook_type) (PlannerInfo *root,
                                          RelOptInfo *rel,
                                          Index rti,
                                          RangeTblEntry *rte);
extern PGDLLIMPORT set rel pathlist hook type set rel pathlist hook;
typedef void (*set join pathlist hook type) (PlannerInfo *root,
                                           RelOptInfo *joinrel,
                                           RelOptInfo *outerrel,
                                           RelOptInfo *innerrel,
                                           JoinType jointype,
                                           JoinPathExtraData *extra);
extern PGDLLIMPORT set join pathlist hook type set join pathlist hook;
CustomPath 構造体
typedef struct CustomPath
                                       // Path 共通部分
               path;
    Path
    uint32
                                       // CUSTOMPATH * flags
              flags;
              *custom_private; // プライベート領域
    List
    const CustomPathMethods *methods; // コールバック関数
} CustomPath;
```

# Custom Scan/Joinを使うには (2/3)

- CustomPath → CustomScan
  - プラナーがCustomPathを選択
  - → CustomScanノードを生成する 必要がある
- どういう事か?
  - CustomPathから生成されるのは、 CustomScanだけではない。(将来的に)✓ CustomSort、CustomAgg、...
  - プラン木はcopyObject()可能である事
  - → GpuScanの例

```
/* Path information of GpuScan */
typedef struct {
    CustomPath cpath;
    /* RestrictInfo run on host */
    List    *host_quals;
    /* RestrictInfo run on devices */
    List    *dev_quals;
} GpuScanPath;
```

- CustomScan → CustomScanState
  - エグゼキュータの開始時に、 CustomScanノードの内容に基づいて CustomScanStateを初期化。

```
→ GpuScanの例 CustomScanStateを継承

typedef struct {
    GpuTaskState gts;

    BlockNumber curr_blknum;
    BlockNumber last_blknum;
    HeapTupleData scan_tuple;
    List *dev_quals;

    cl_uint num_rechecked;
} GpuScanState;
```

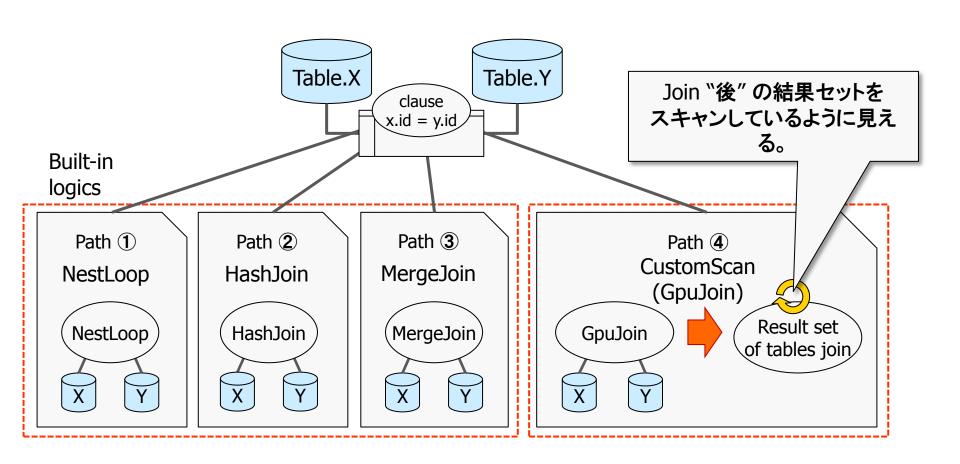
# Custom Scan/Joinを使うには (3/3)

#### Executorコールバックを各自実装する

```
typedef struct CustomExecMethods
{
    const char *CustomName;
    /* Executor methods: mark/restore are optional, the rest are required */
                (*BeginCustomScan) (struct CustomScanState *node,
    void
                                    EState *estate.
                                    int eflags);
    TupleTableSlot *(*ExecCustomScan) (struct CustomScanState *node);
                (*EndCustomScan) (struct CustomScanState *node);
    void
    void
                (*ReScanCustomScan) (struct CustomScanState *node);
    void
                (*MarkPosCustomScan) (struct CustomScanState *node);
                (*RestrPosCustomScan) (struct CustomScanState *node);
    void
    /* Optional: print additional information in EXPLAIN */
    void
                (*ExplainCustomScan) (struct CustomScanState *node,
                                      List *ancestors,
                                      struct ExplainState *es);
} CustomExecMethods;
```

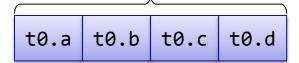
### CustomJoinはどう見えるか?

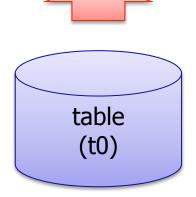
#### CustomScanによる Join の置換え



### 結果セットのレコード型

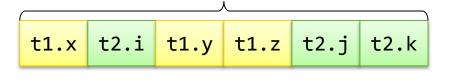
結果セットのレコード型は、 常にテーブル定義と一致

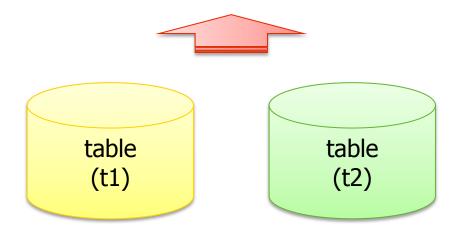




単純なスキャン

結果セットのレコード型は、 時と場合によって異なる

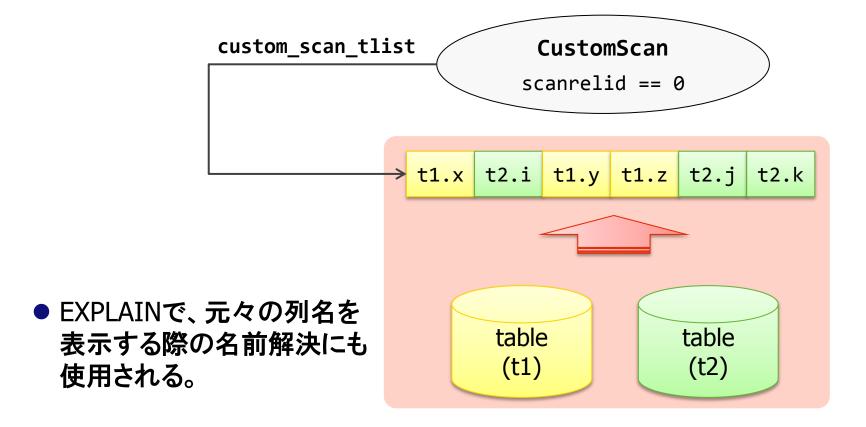




複数のテーブルから成るジョイン

### scanrelid == 0 \(\mathcal{E}\) custom\_scan\_tlist

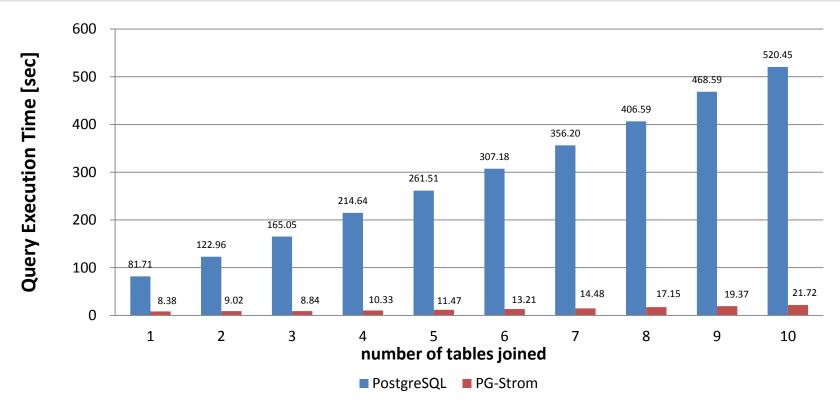
- scanrelid == 0
  - CustomScanが特定の実テーブルスキャンでない事を示す Magic Number
  - custom\_scan\_tlist で指定されたレコード型をスキャンすると見なす。



### CustomScanを含むクエリ実行計画

```
postgres=# EXPLAIN SELECT cat, AVG(x)
   FROM to NATURAL JOIN t1 RIGHT JOIN t2 ON to.aid=t2.bid OR to.bid=t2.bid
   WHERE atext like '%abc%' GROUP BY cat;
                                  OUERY PLAN
HashAggregate (cost=348362.37..348362.70 rows=26 width=12)
 Group Key: t0.cat
  -> Custom Scan (GpuPreAgg) (cost=2134.00..348362.24 rows=26 width=52)
    Bulkload: On
    Reduction: Local + Global
     -> Custom Scan (GpuJoin) (cost=1134.00..347362.19 rows=1985 width=12)
       Bulkload: On
       Depth 1: Logic: GpuHashJoin, HashKeys: (aid), JoinQual: (aid = aid)
       Depth 2: Logic: GpuNestLoop, JoinQual: ((aid = bid) OR (bid = bid))
        -> Custom Scan (GpuScan) on t0 (cost=1000.00..143858.00 rows=10000060 ...
        -> Custom Scan (MultiRels) (cost=834.05..343937.39 rows=4 width=4)
          Hash keys: aid
           nBatches: 1, Buckets: 1024, Buffer Usage: 2.33%
           -> Seq Scan on t1 (cost=0.00..834.00 rows=4 width=4)
              Filter: (atext ~~ '%abc%'::text)
           -> Custom Scan (MultiRels) (cost=1134.00..347362.19 rows=40000 width=4)
              nBatches: 1, Buffer Usage: 97.64%
              -> Seq Scan on t2 (cost=0.00..734.00 rows=40000 width=4)
```

### CustomにJoinを実装してみた結果



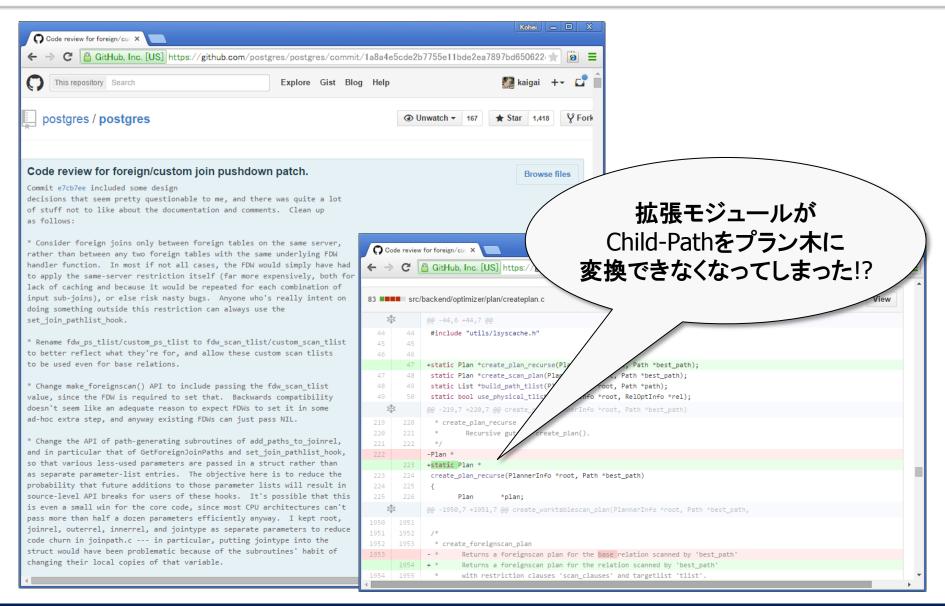
■ SELECT cat, AVG(x) FROM t0 NATURAL JOIN t1 [, ...] GROUP BY cat; を テーブル数を変えながら実行してクエリ応答時間を測定。

t0:1億行、t1~t10:それぞれ10万行を含む。全データはバッファにロード済み。

PostgreSQL v9.5devel + PG-Strom 5/26開発版、on CUDA7 (x86\_64)

CPU: Xeon E5-2640, RAM: 256GB, GPU: NVIDIA GTX980, OS: RedHat EL7

### v9.5に向けての Open Issue



# もふっ、もふもふ。

