SQL+GPU+SSD=∞

かぴばら@品川

自己紹介

- Name: かぴばら@品川
- PostgreSQL歴：9年ほど（2006~）
- works: セキュリティ周り、FDW周り、諸々…
- 趣味： 別業界のテクノロジを持ってきて PostgreSQLに組み合わせる事 （混ぜるな危険？）

Very functional & well-used database

PG-Strom:
なるものを作っています。

GPGPU

Very powerful computing capability

What's PG-Strom – ざっくり説明すると

コア機能

① SQLからGPUネイティブバイナリを動的に生成する。

② GPUによる "超"並列処理を非同期に実行する。

利点

- SQLクエリを透過的にアクセラレーション可能。
- 一般的なH/Wを使って構成可能。安価。

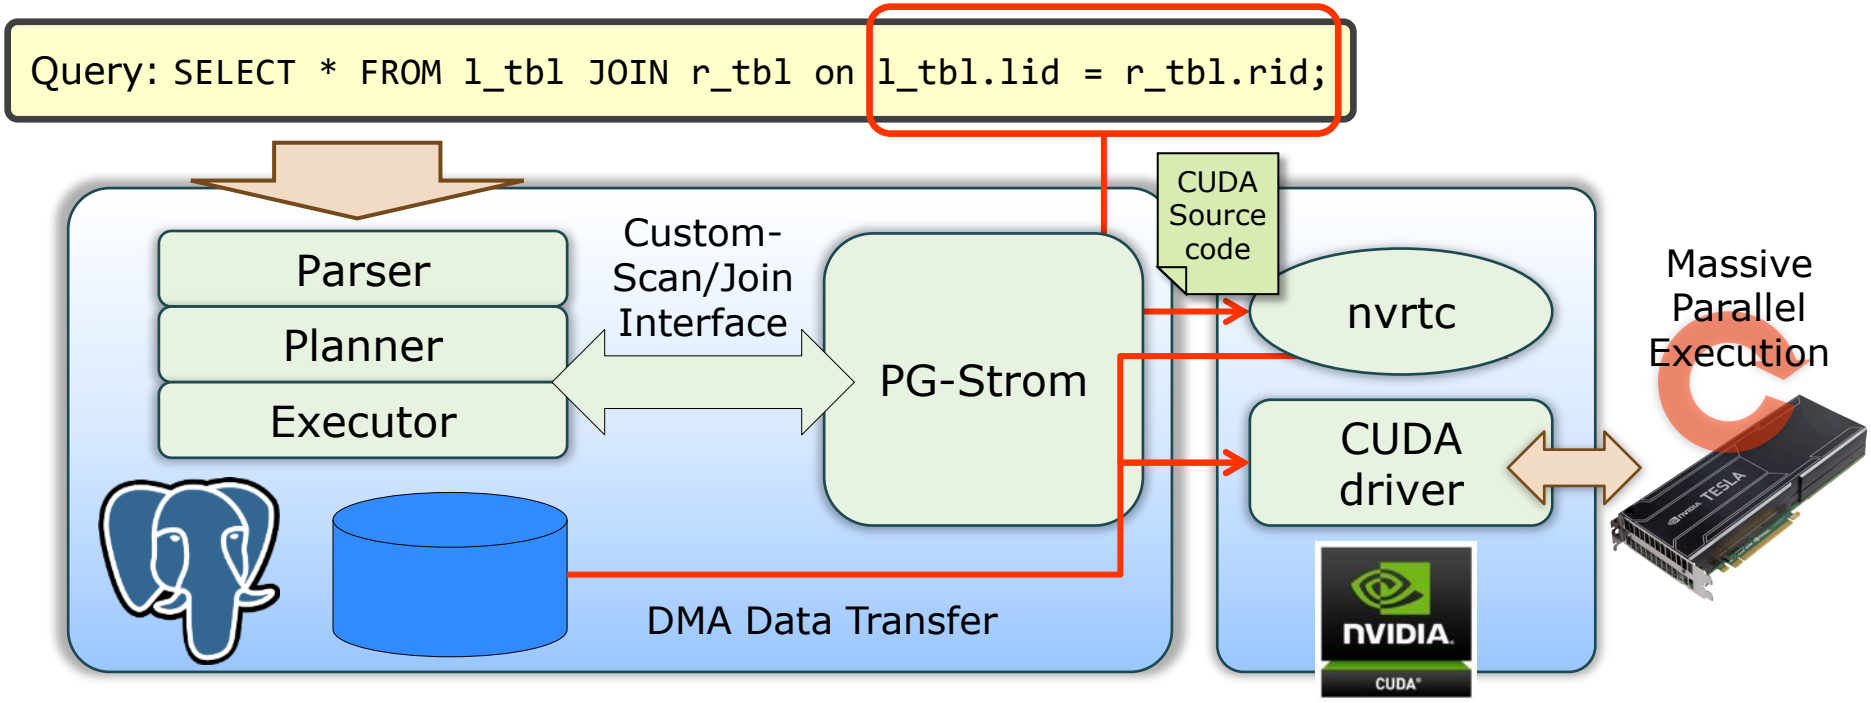

対応ワークロード – Scan, Join, Aggregation

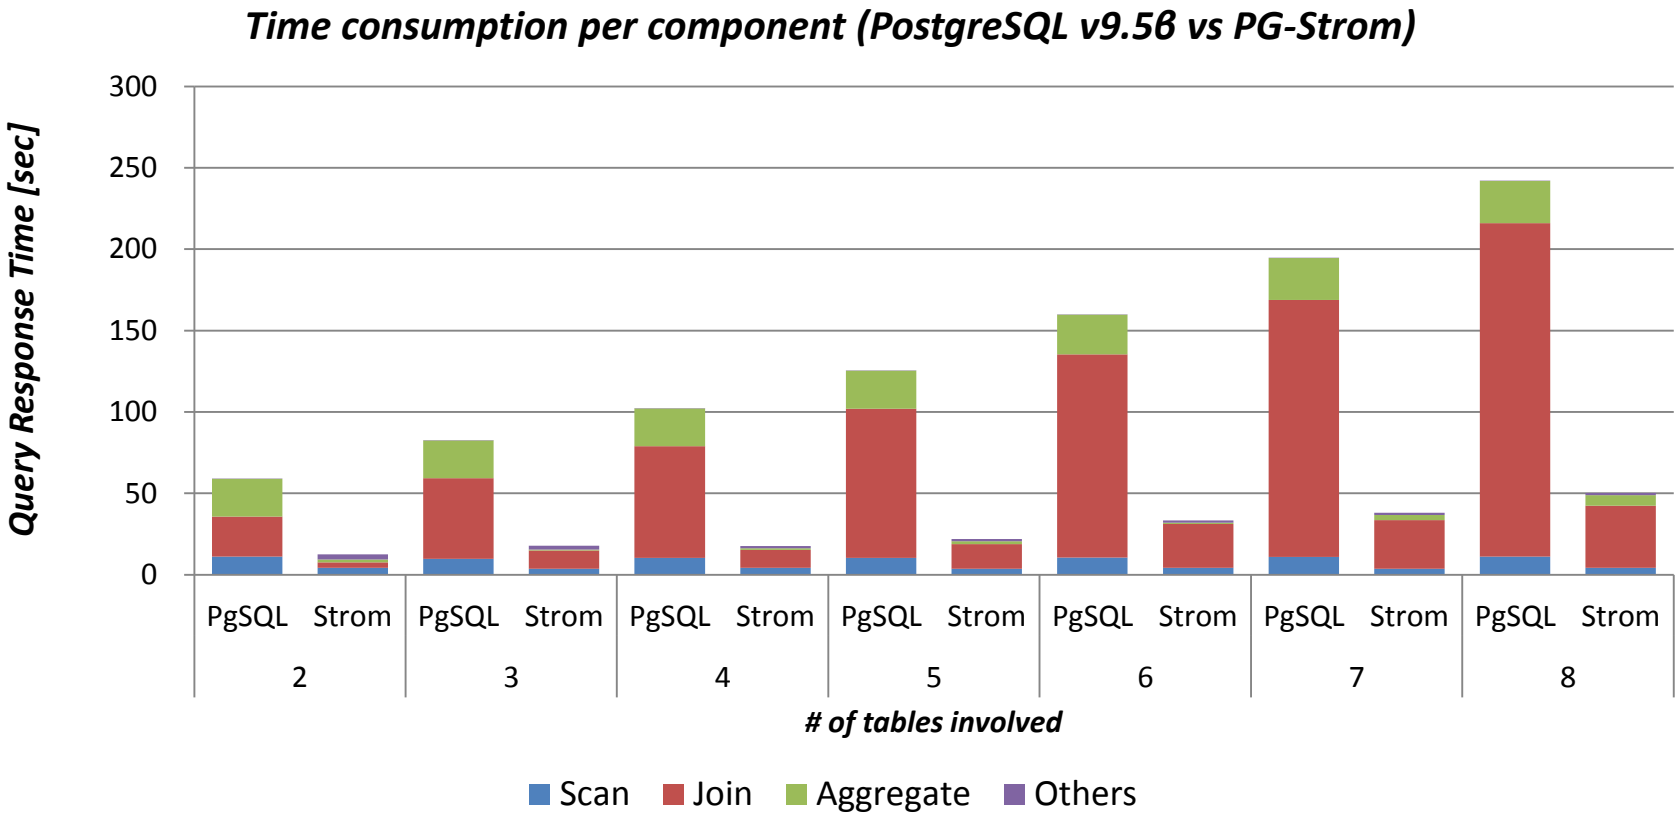

- `SELECT cat, AVG(x) FROM t0 NATURAL JOIN t1 [, ...] GROUP BY cat;`
  - `t0`: 100M rows, t1~t10: 100K rows for each, all the data was preloaded.
- **測定環境:**
  - PostgreSQL v9.5beta1 + PG-Strom (22-Oct), CUDA 7.0 + RHEL6.6 (x86_64)
  - CPU: Xeon E5-2670v3, RAM: 384GB, GPU: NVIDIA TESLA K20c (2496cores)

次のターゲットはI/O – TPC/DSワークロードの解析より

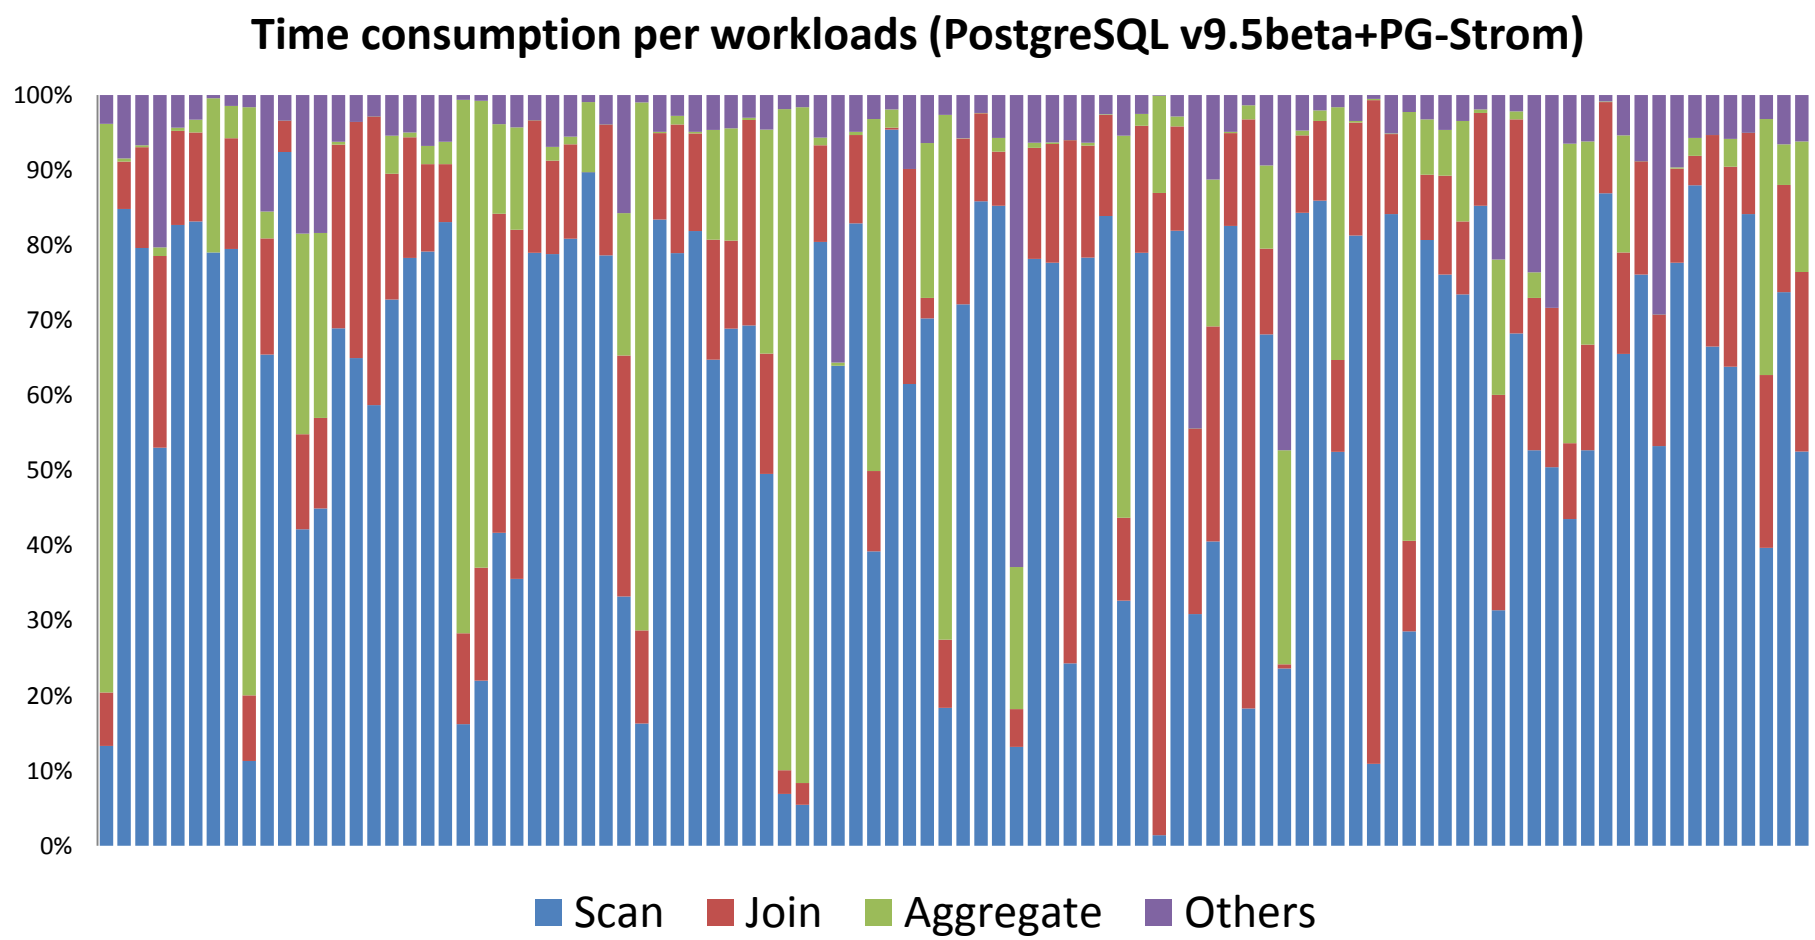

では、どうやってGPUでI/Oを高速化しようというのか？

お断り。

今からご紹介する話は、

現在のところ**実装アイデア**です。

……これから頑張って作りますよ。

大雑把な x86 ハードウェアの構成

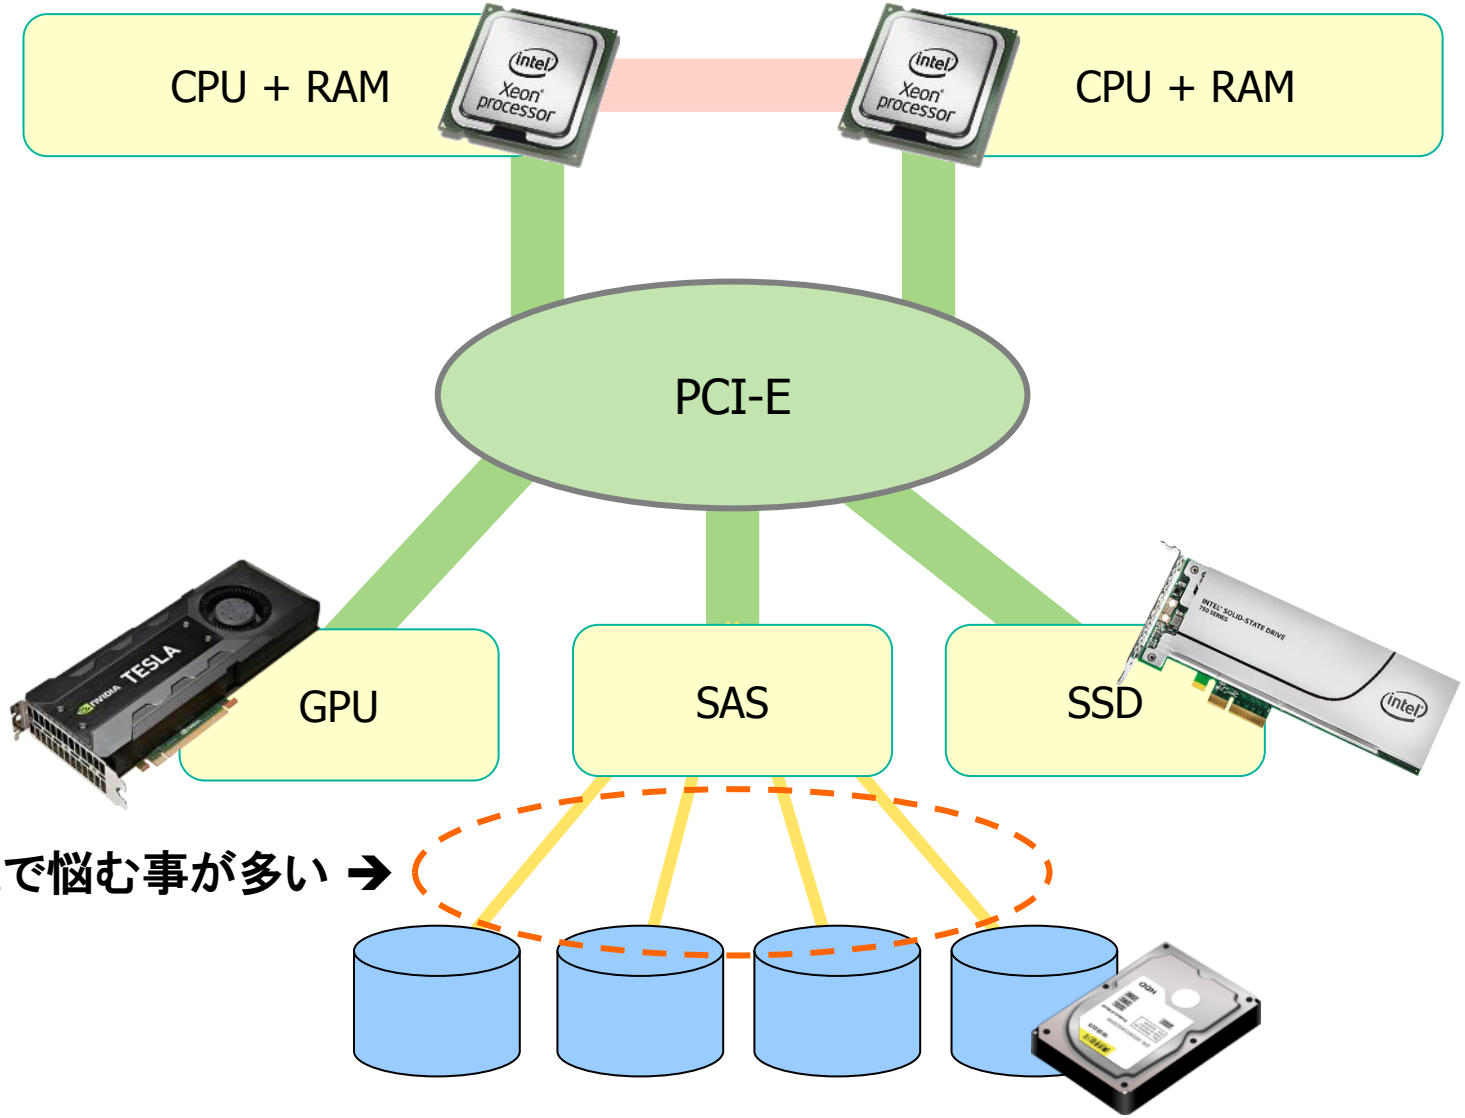

説明のため図を単純化します

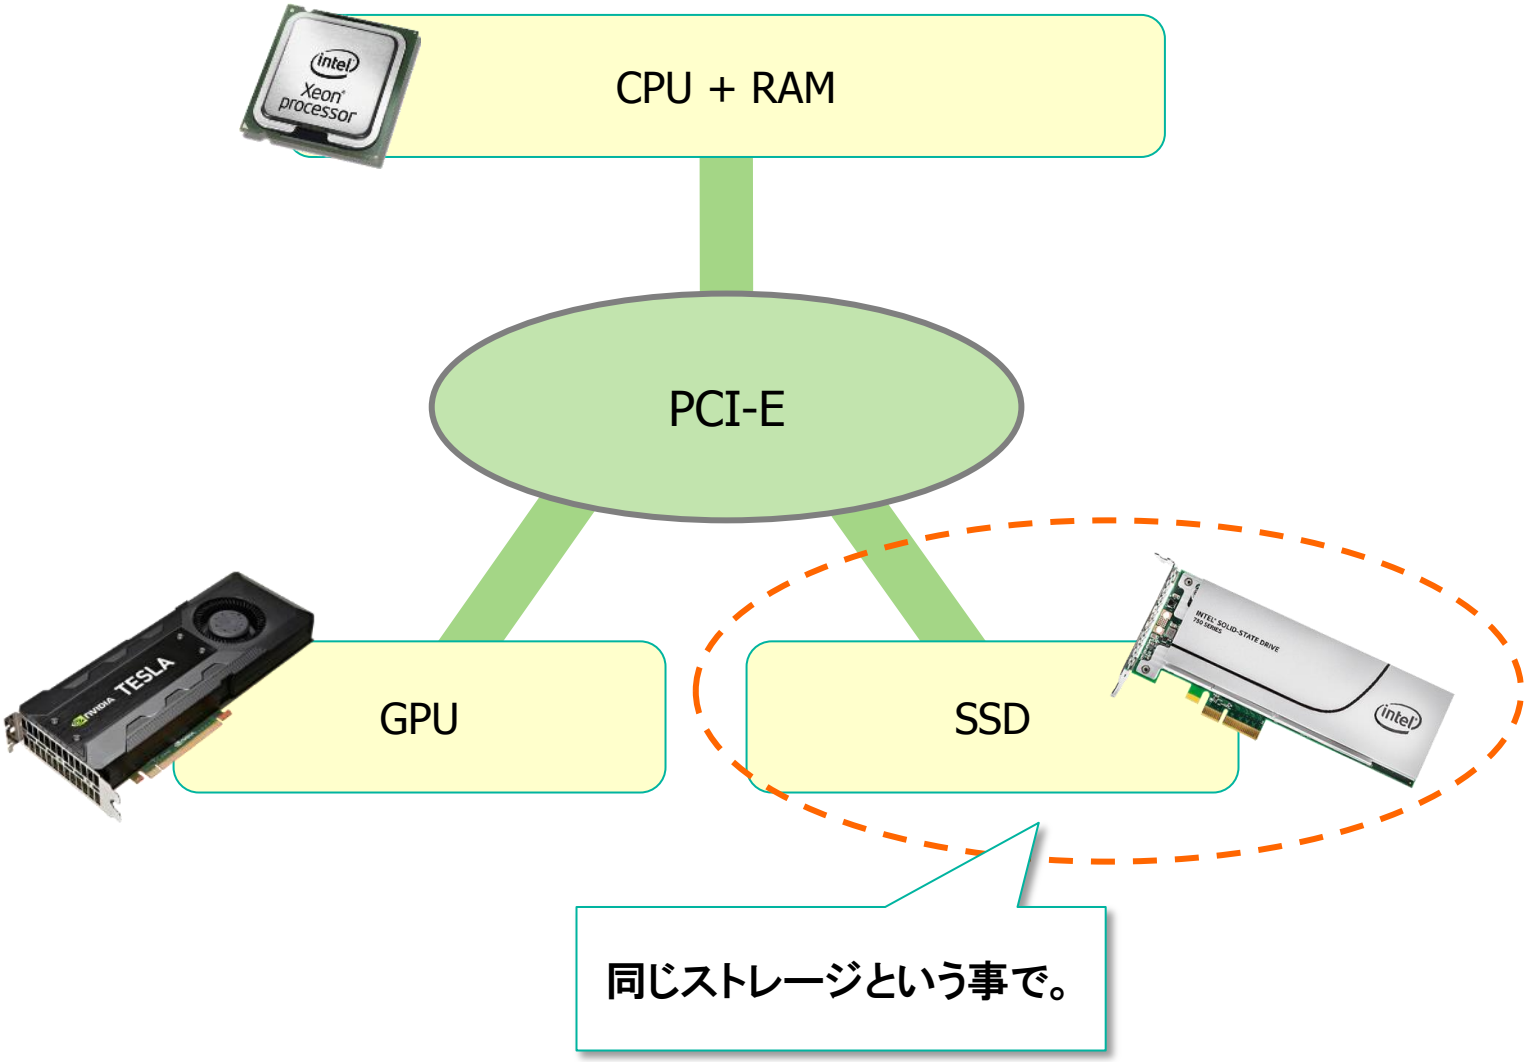

NVM EXPRESS SSD

PCI-Eダイレクト接続タイプのSSD – 低レイテンシと広帯域が特長

HGST
Ultrastar SN100

Intel
SSD DC P3700

Intel SSD 750

Samsung
SSD 950 PRO

解析系クエリ実行時のデータフロー

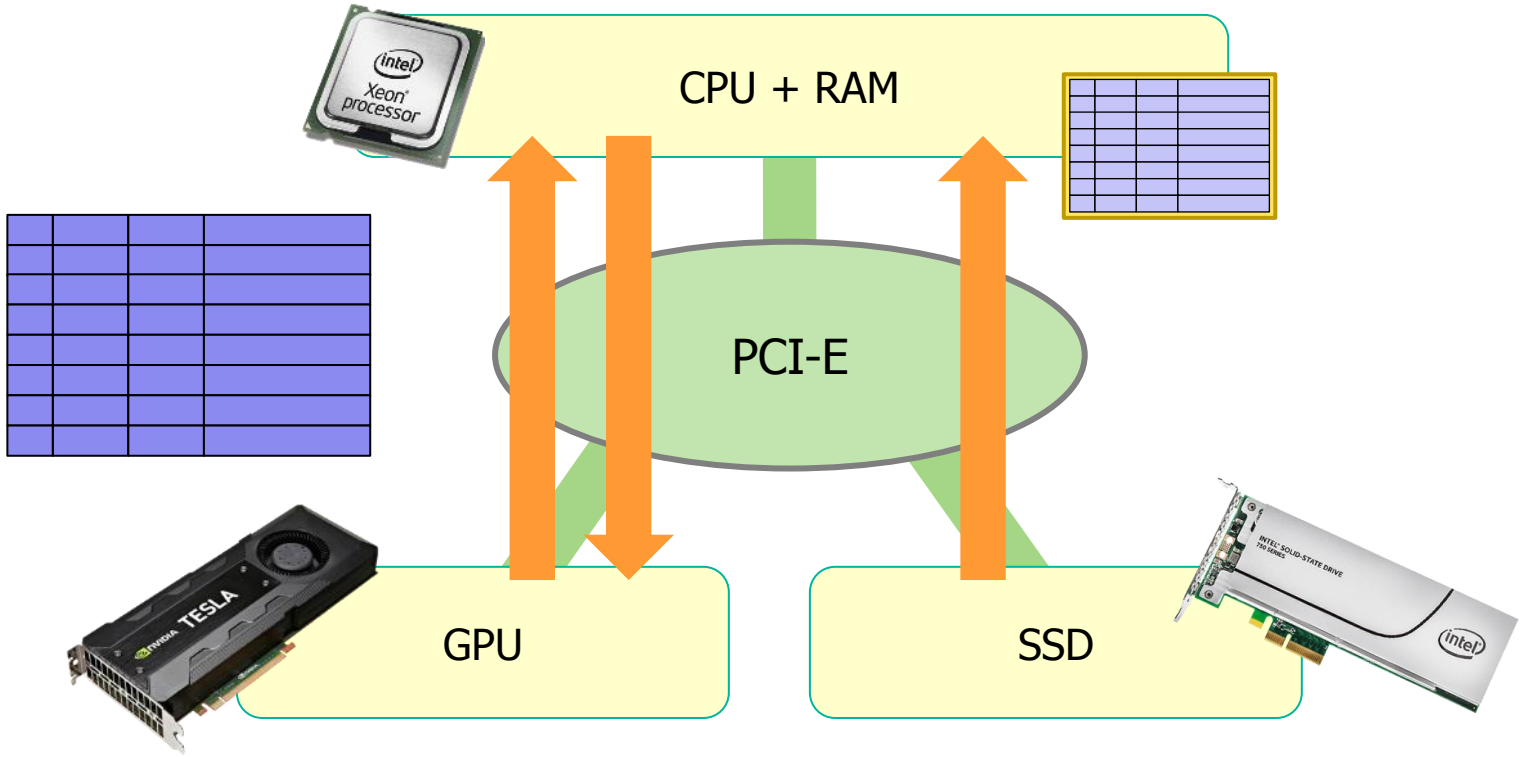

① ストレージ ➔ CPU/RAMへデータをロード

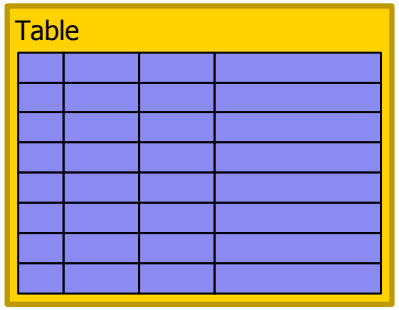

解析系クエリ実行時のデータフロー

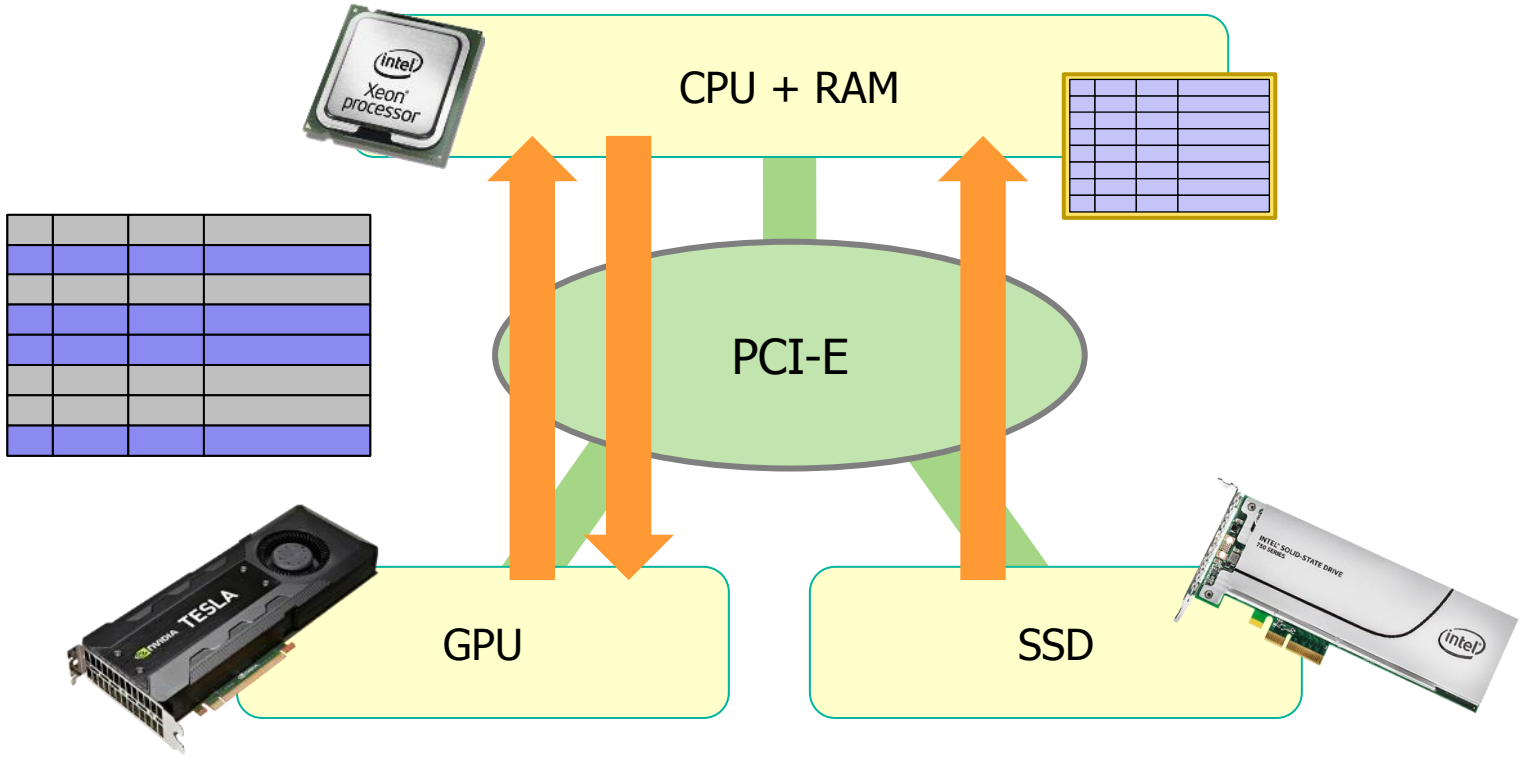

① ストレージ ➔ CPU/RAMへデータをロード
② 条件句で行をフィルタリング（Select）

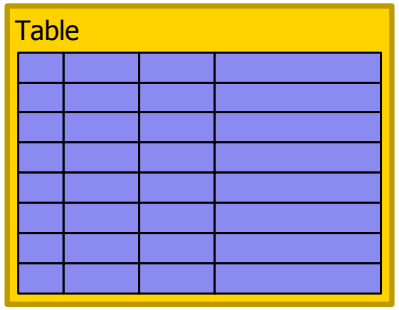

解析系クエリ実行時のデータフロー

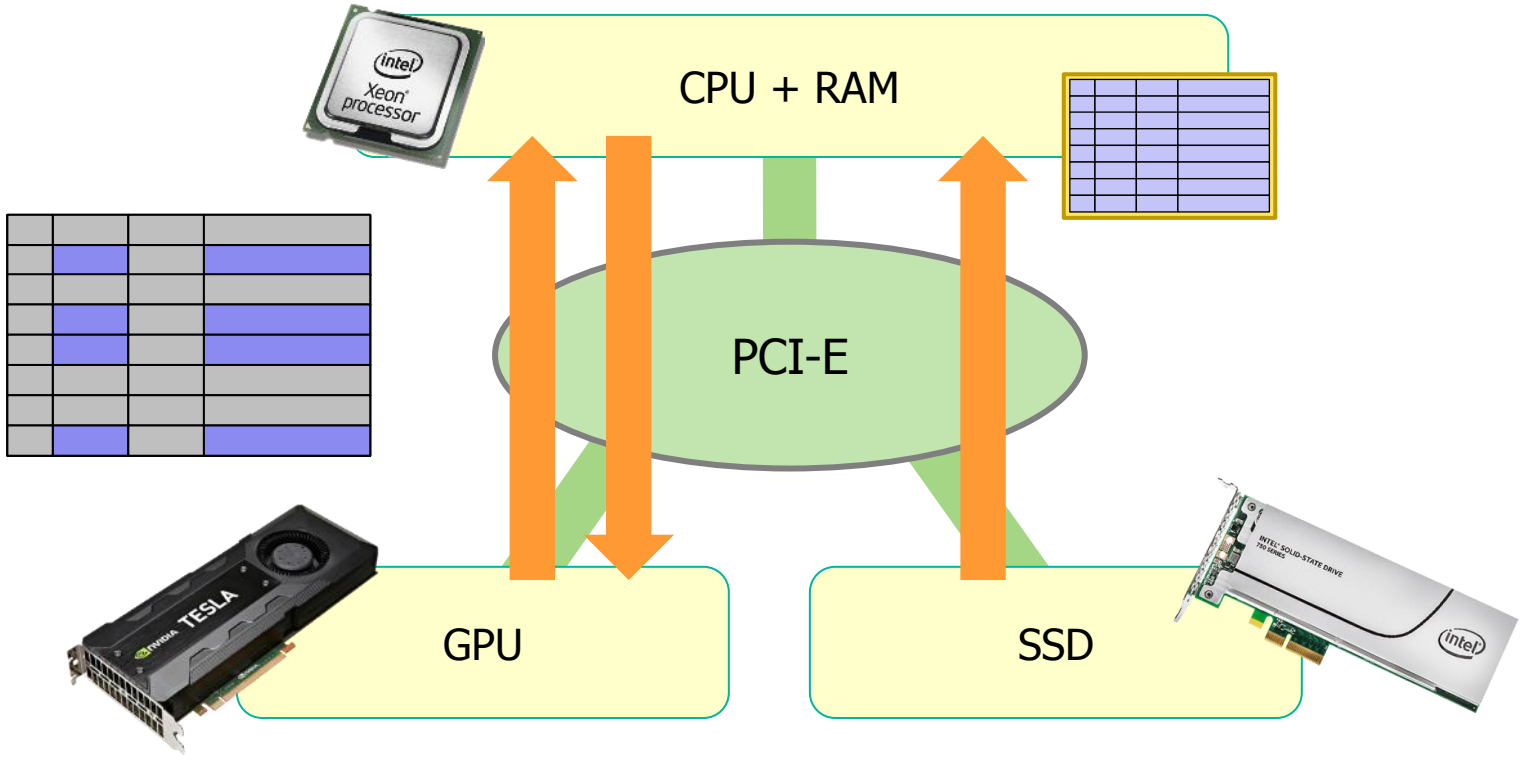

① ストレージ ➔ CPU/RAMへデータをロード
② 条件句で行をフィルタリング(Select)
③ 参照されない列を除去(Projection)

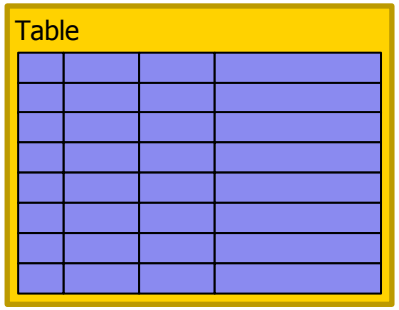

解析系クエリ実行時のデータフロー

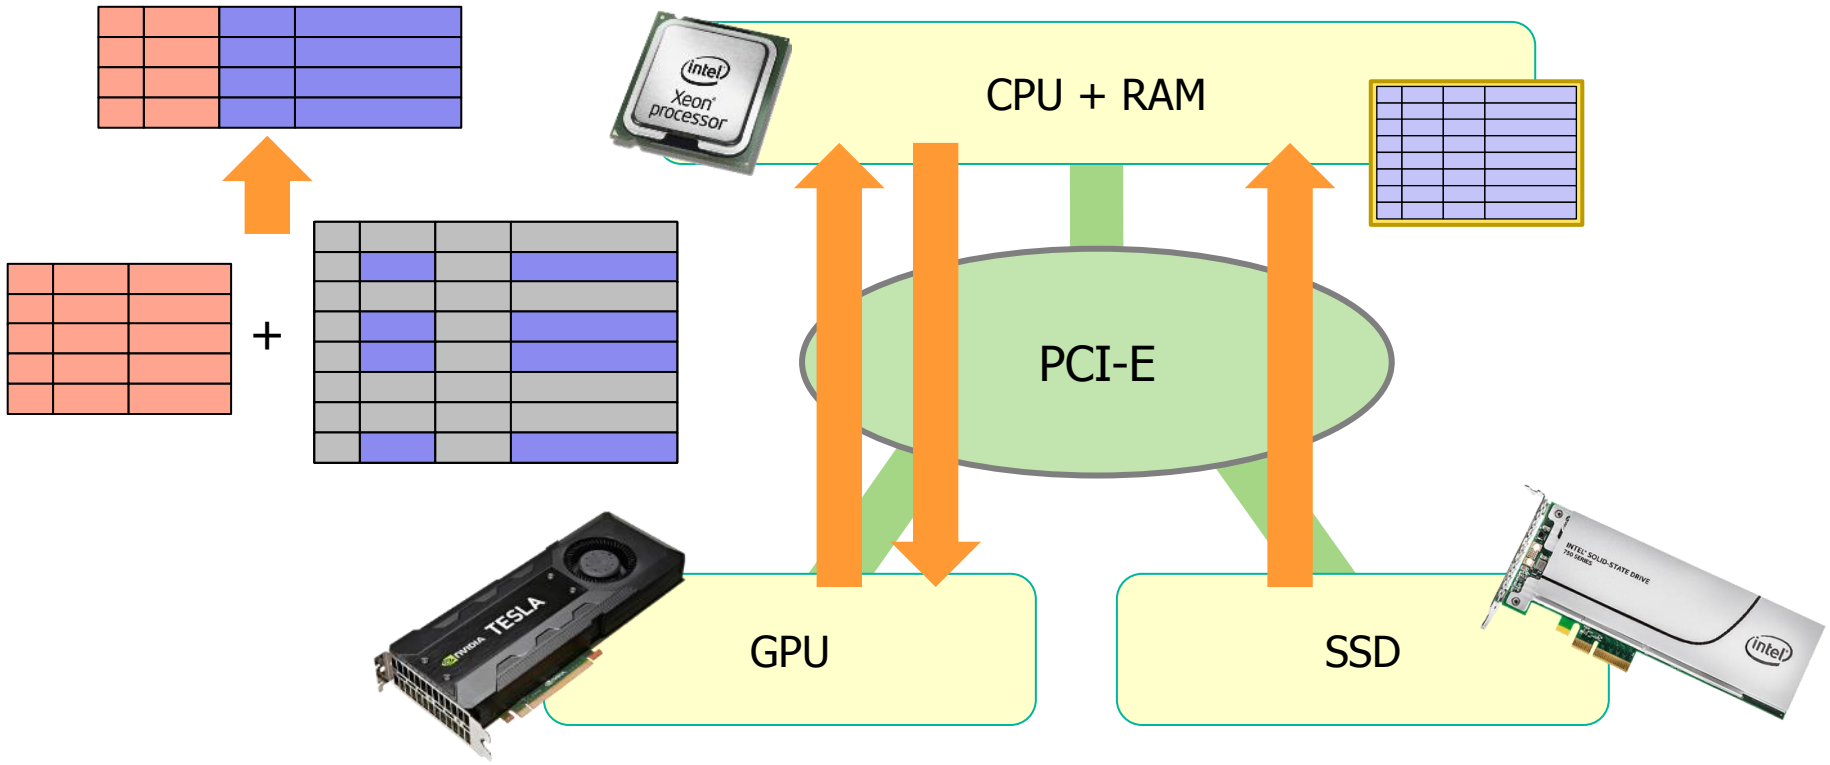

① ストレージ ➔ CPU/RAMへデータをロード
② 条件句で行をフィルタリング(Select)
③ 参照されない列を除去(Projection)
④ 他のテーブルと結合(Join)

↑ CPUの仕事

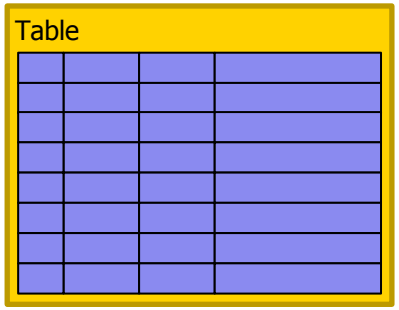

SSD-to-GPU Direct

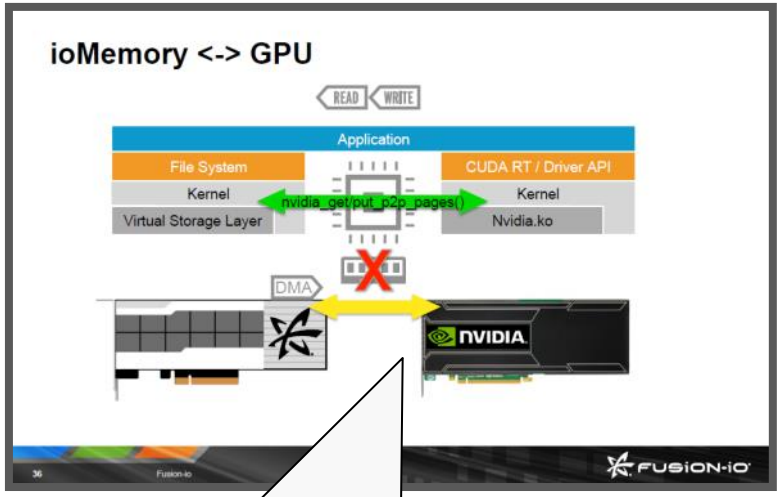

CPU/RAMを介さずに
SSD➔GPU間でデータ転送

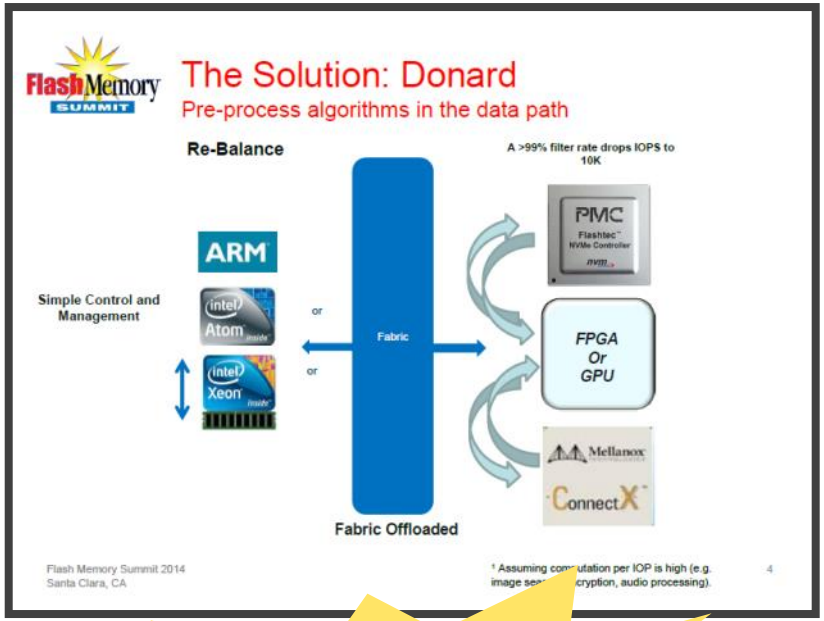

同じ事が標準規格の
NVMeでも可能！

解析系クエリ実行時のデータフロー (1/3) – 基本パターン

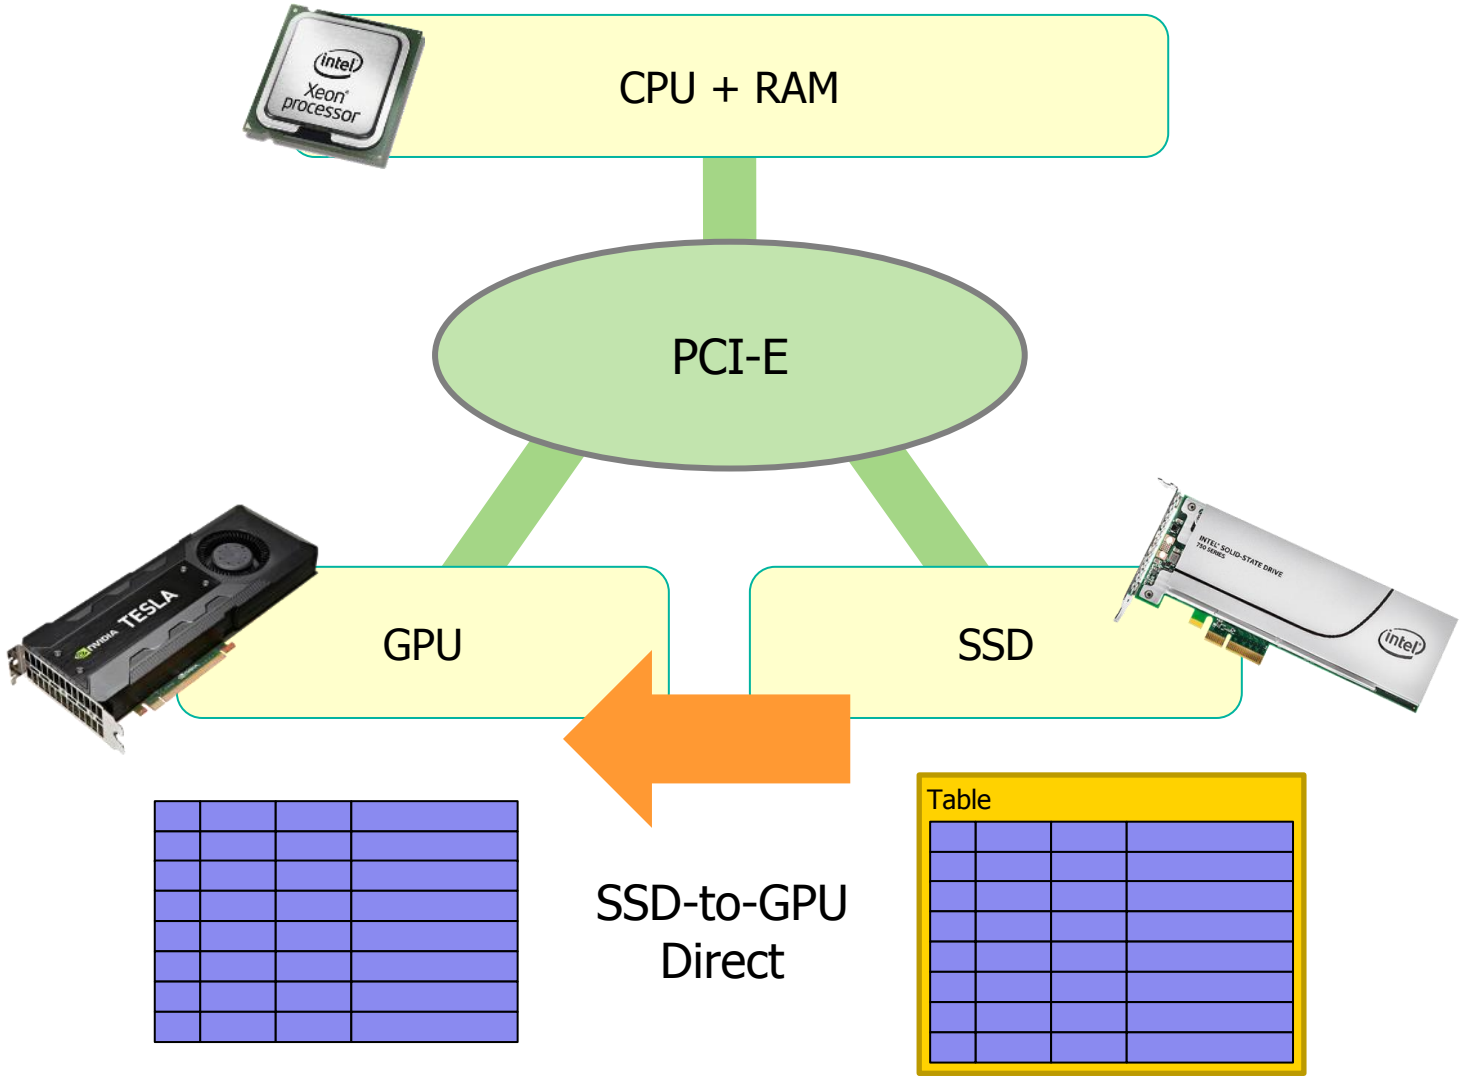

解析系クエリ実行時のデータフロー (1/3) – 基本パターン

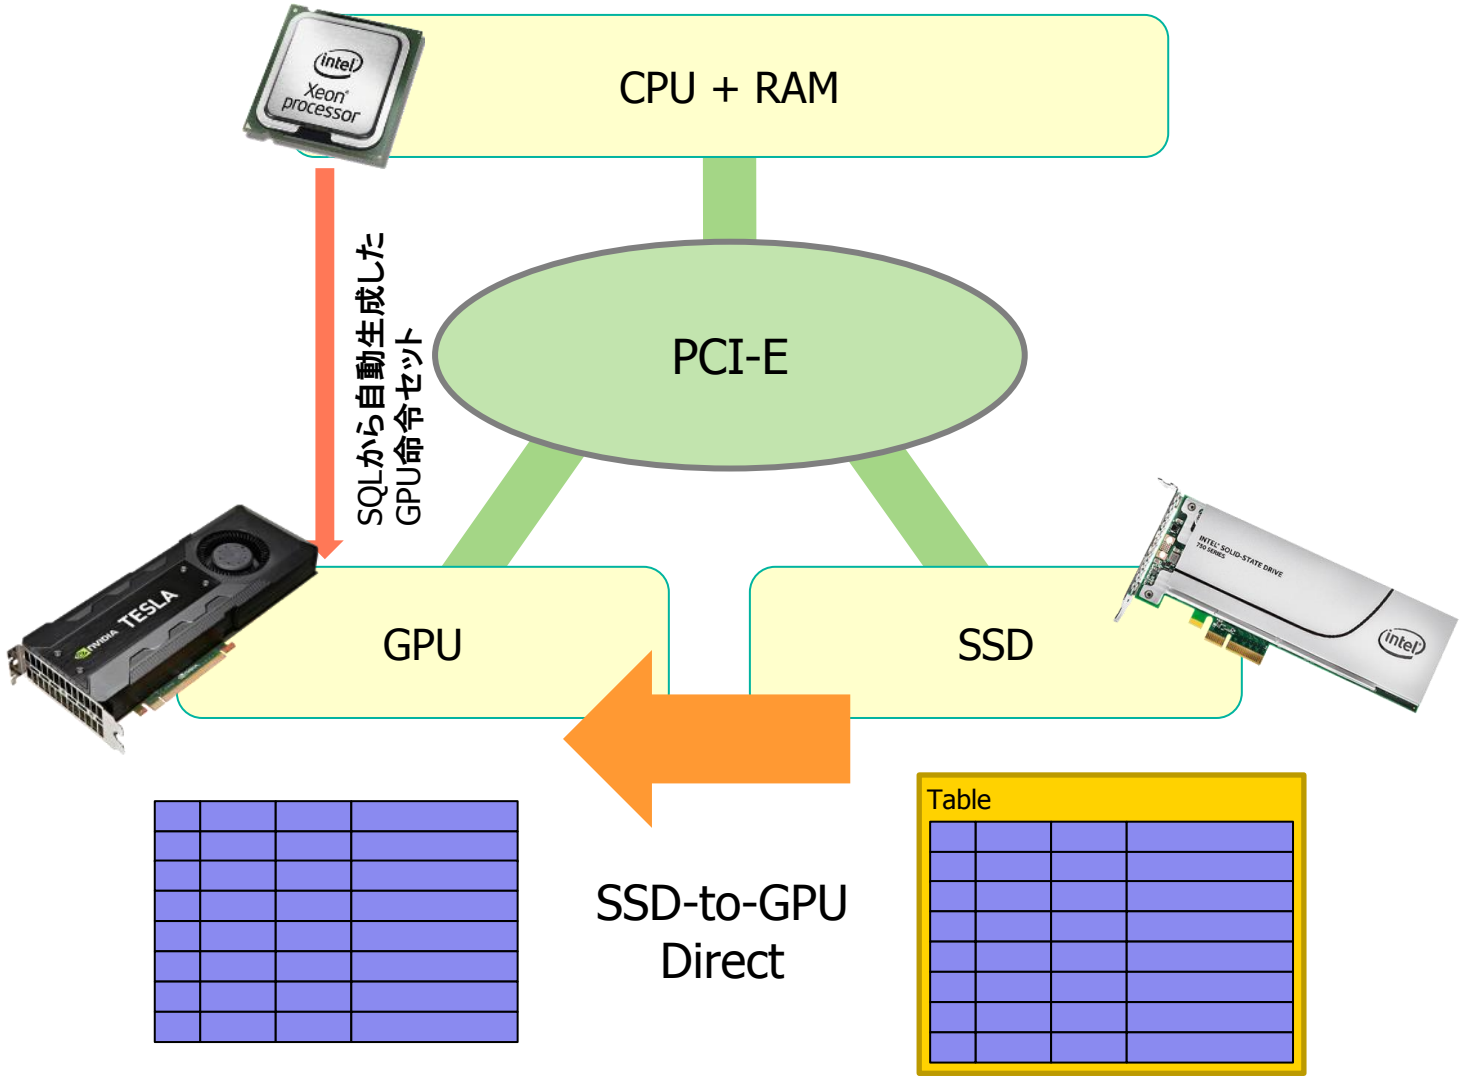

解析系クエリ実行時のデータフロー (1/3) – 基本パターン

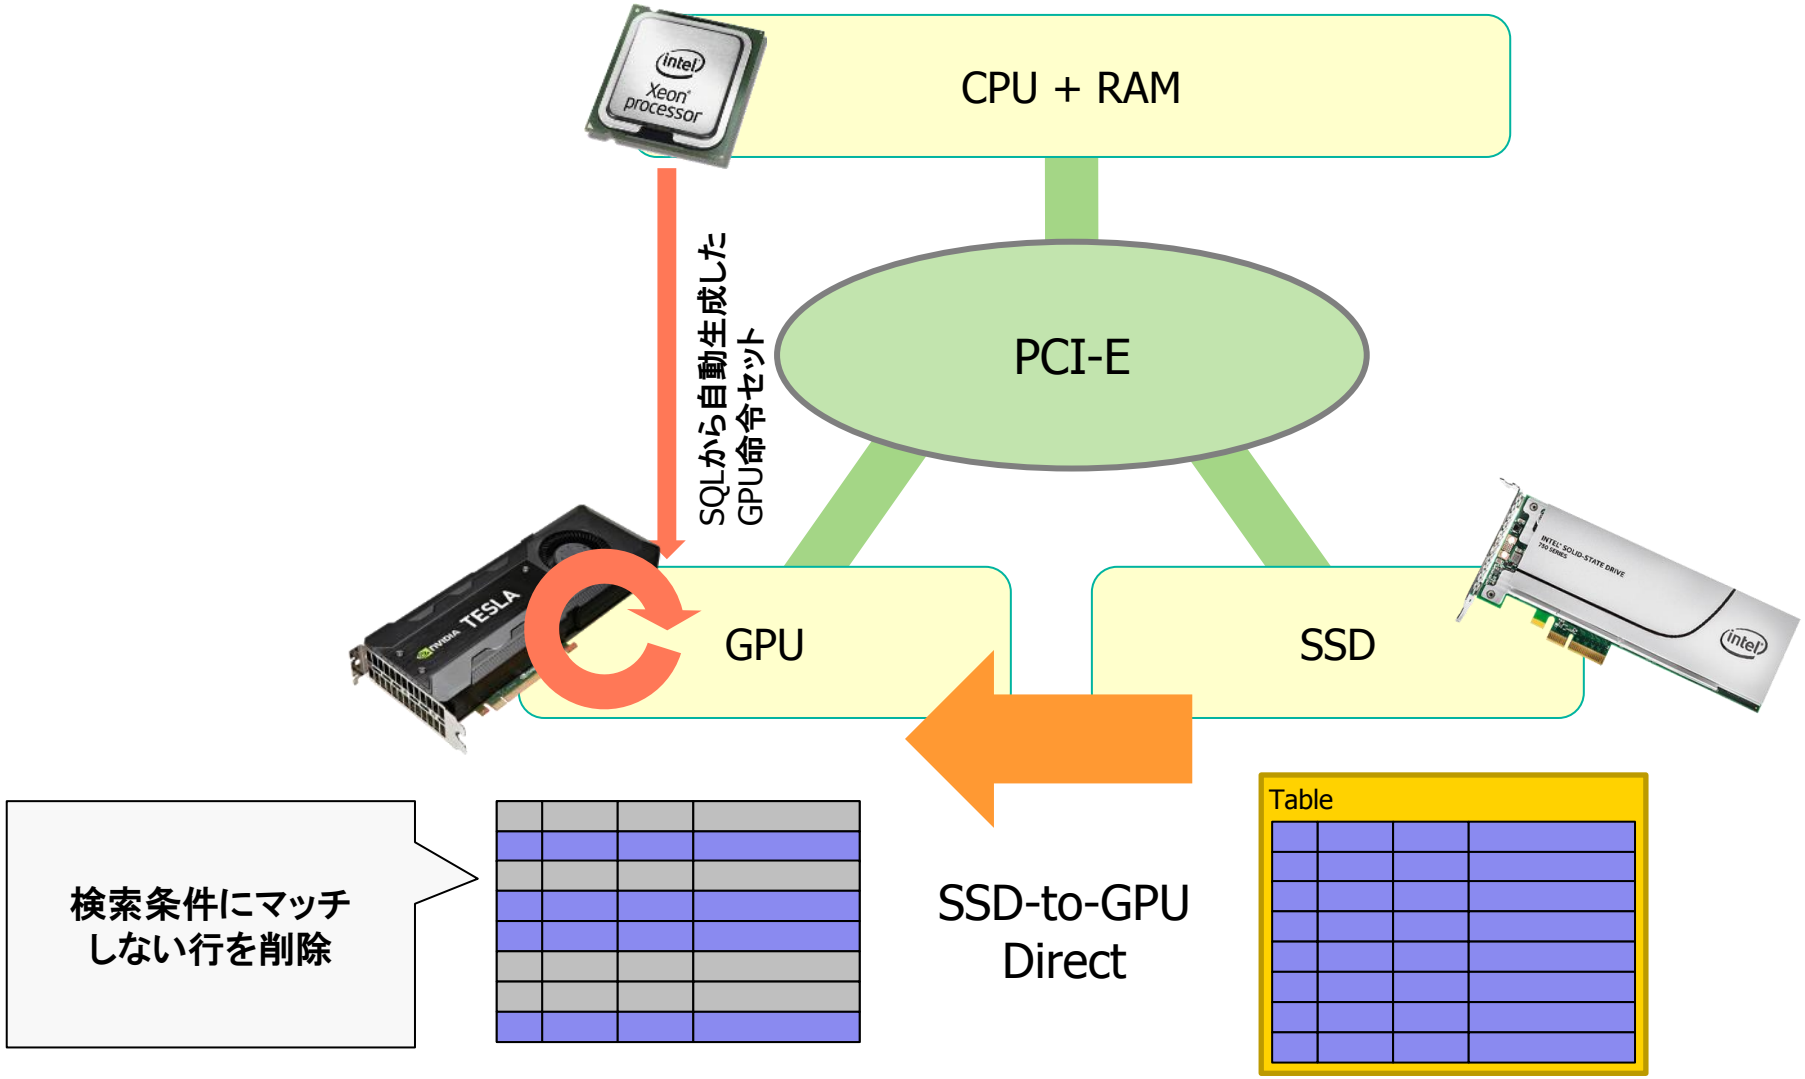

解析系クエリ実行時のデータフロー (1/3) – 基本パターン

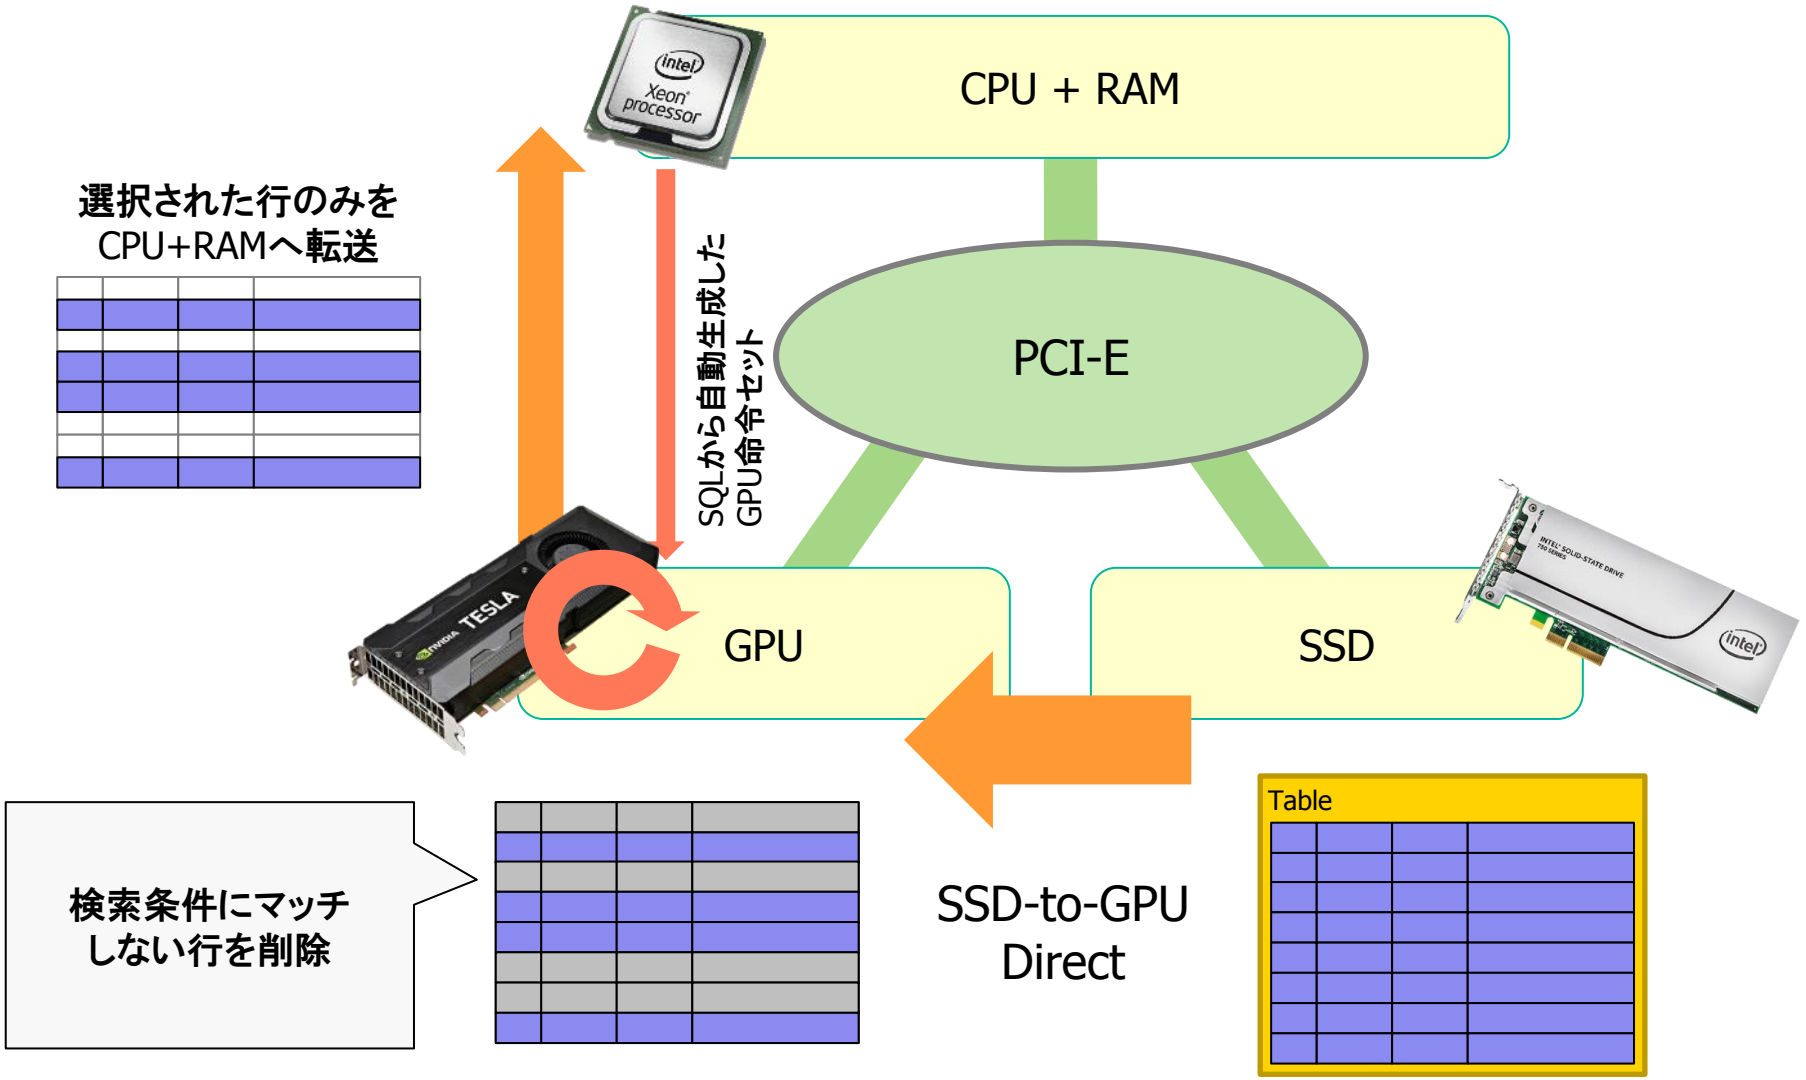

解析系クエリ実行時のデータフロー (2/3) – アレンジ版

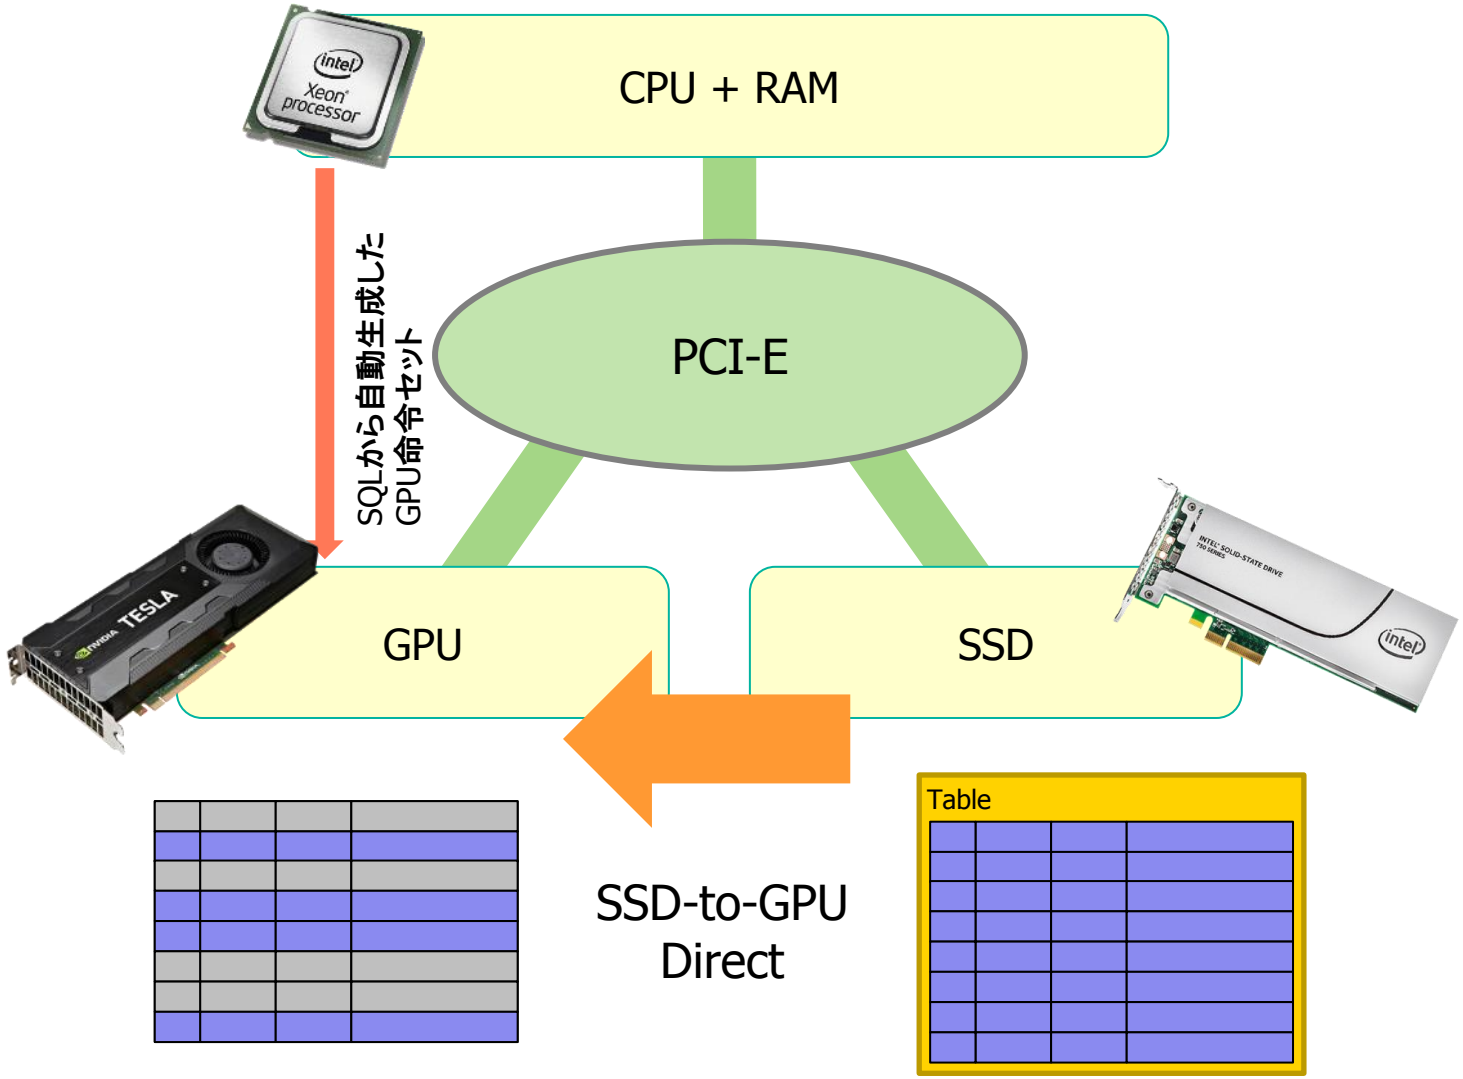

解析系クエリ実行時のデータフロー (2/3) – アレンジ版

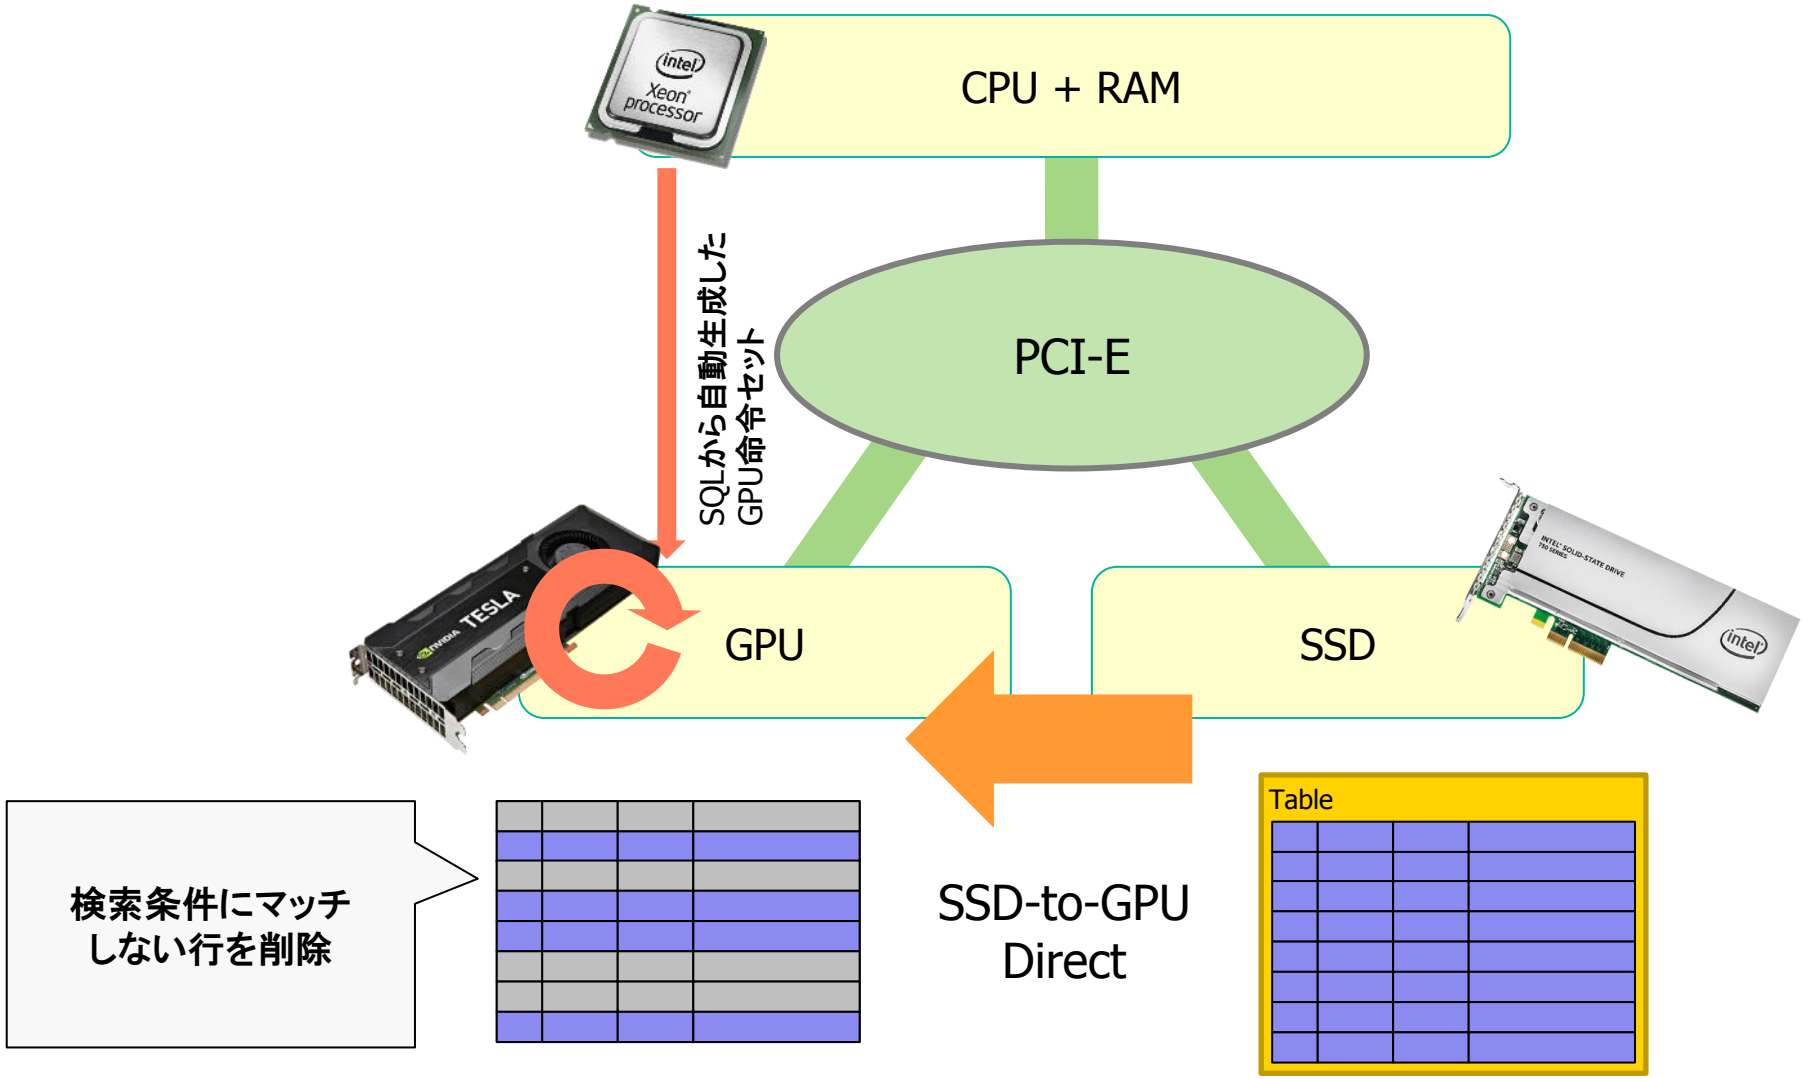

解析系クエリ実行時のデータフロー (2/3) – アレンジ版

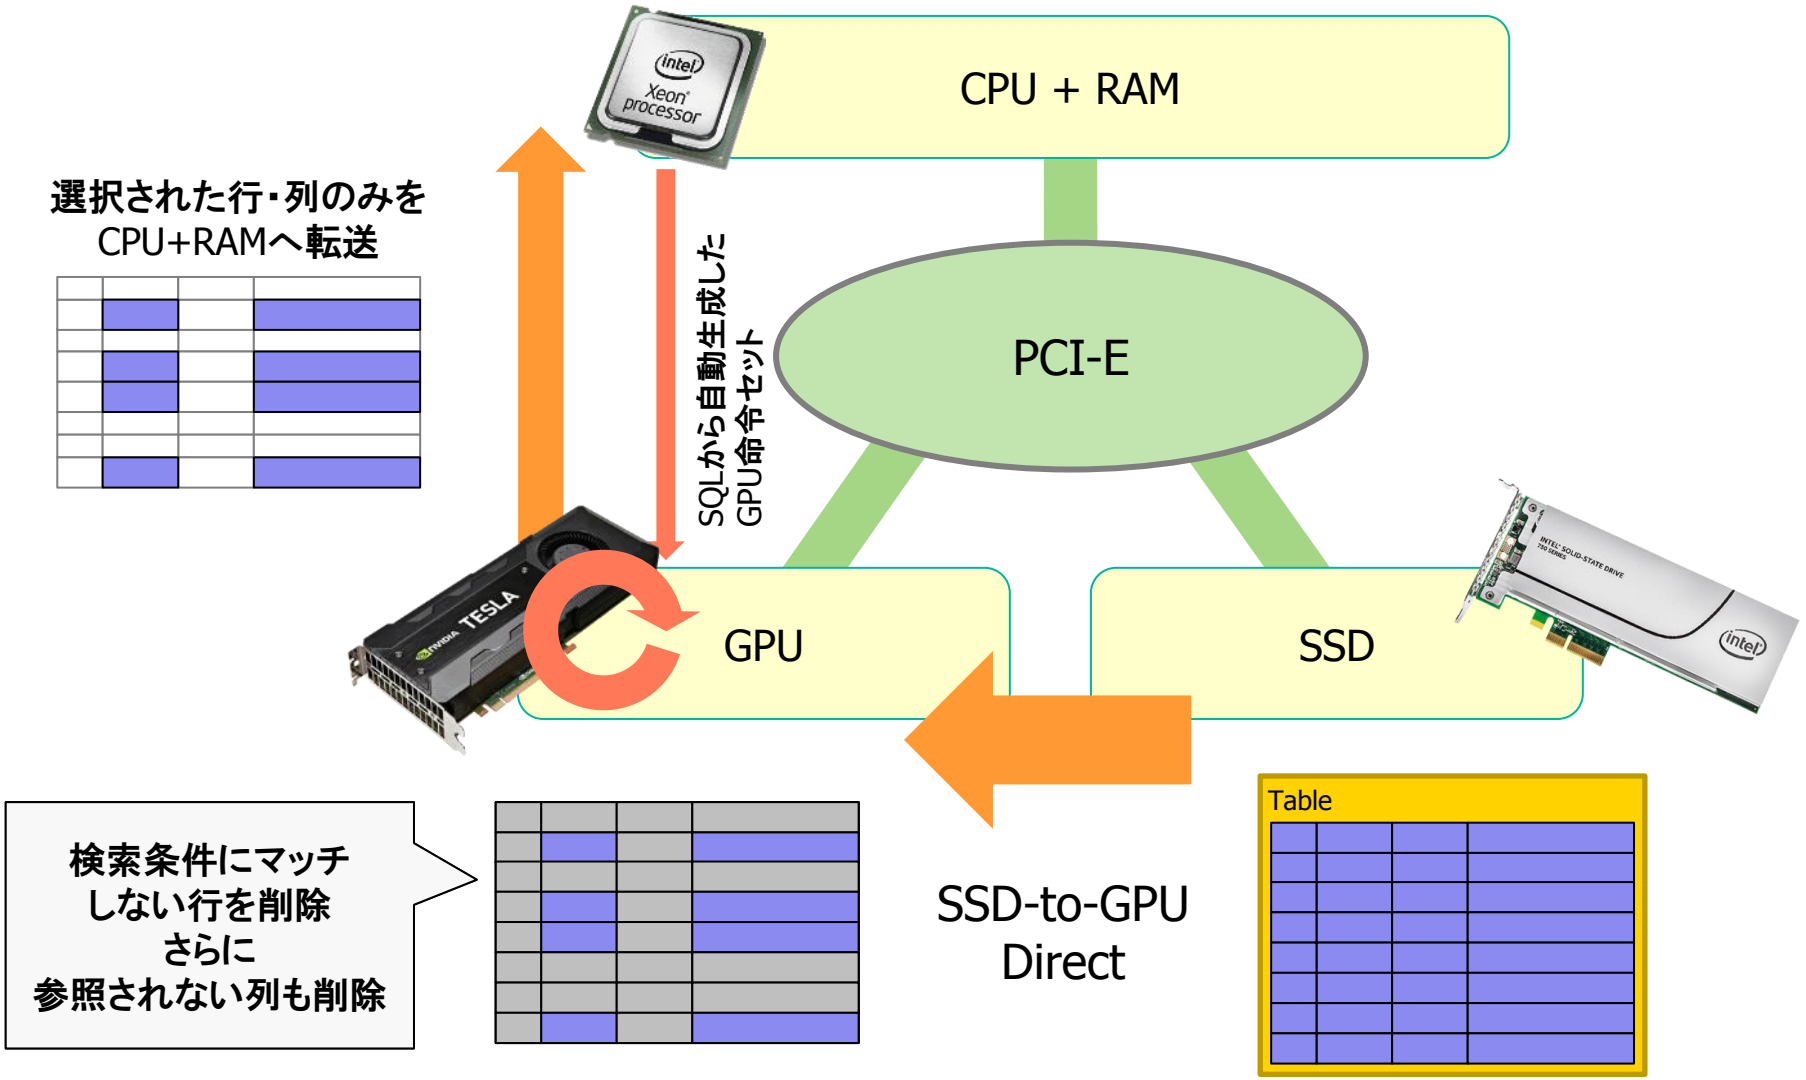

解析系クエリ実行時のデータフロー (3/3) – 鬼アレンジ版

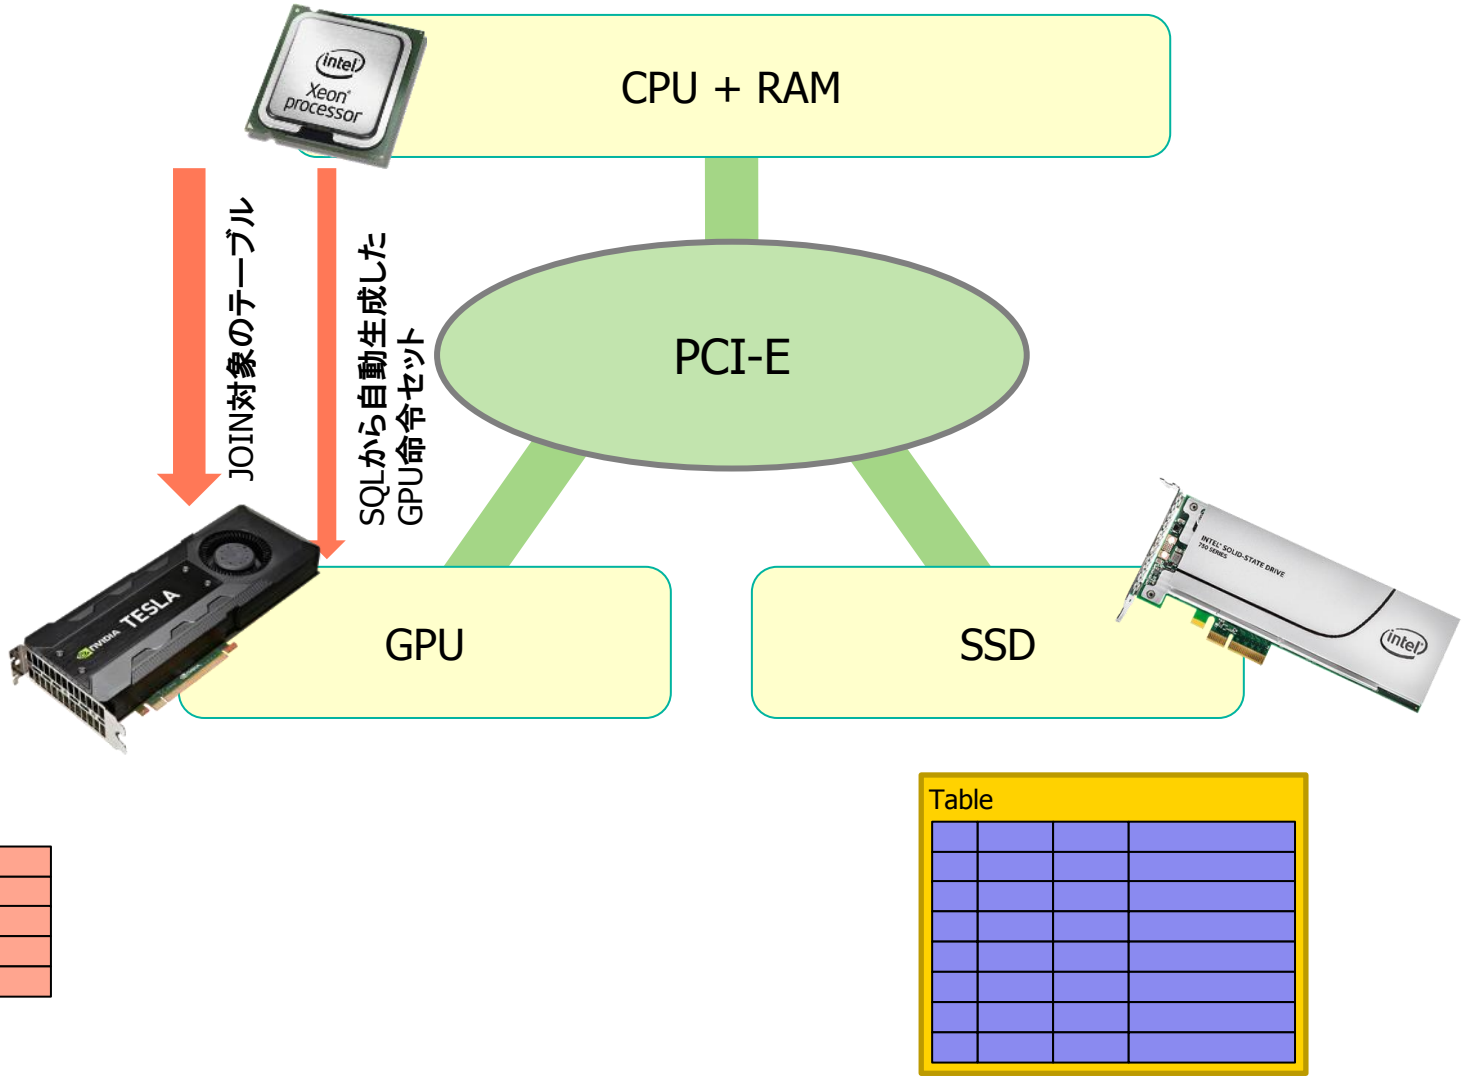

解析系クエリ実行時のデータフロー (3/3) – 鬼アレンジ版

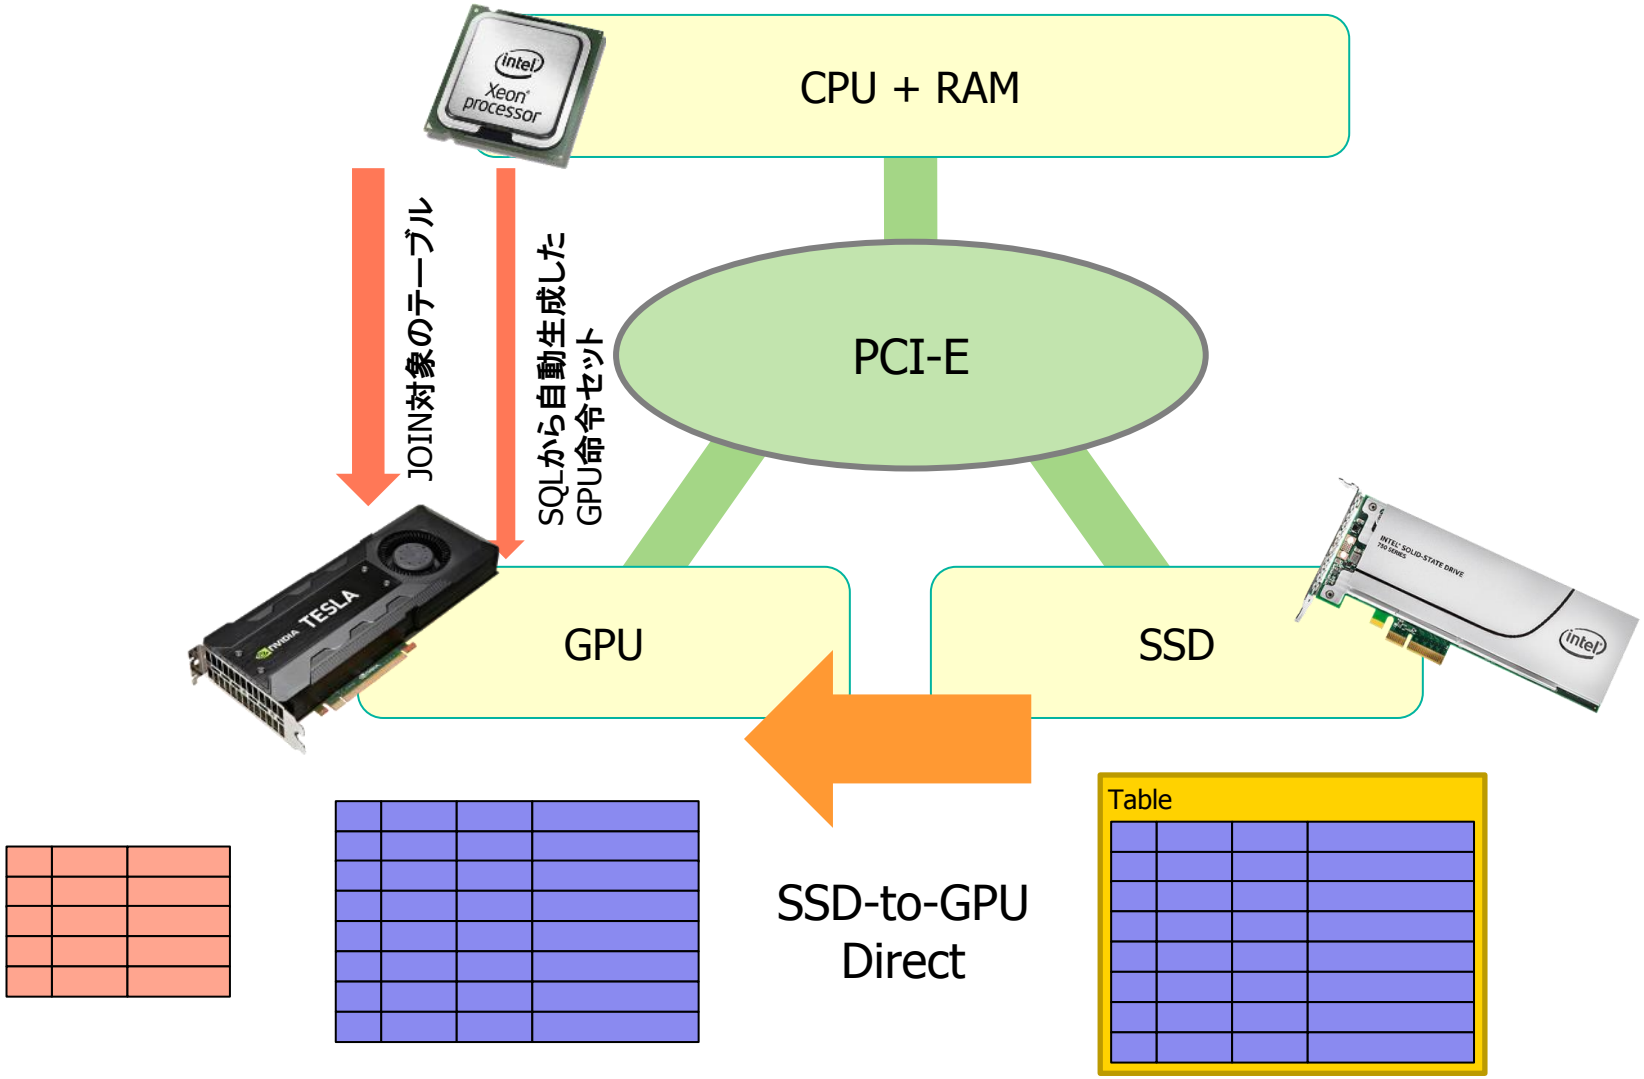

解析系クエリ実行時のデータフロー (3/3) – 鬼アレンジ版

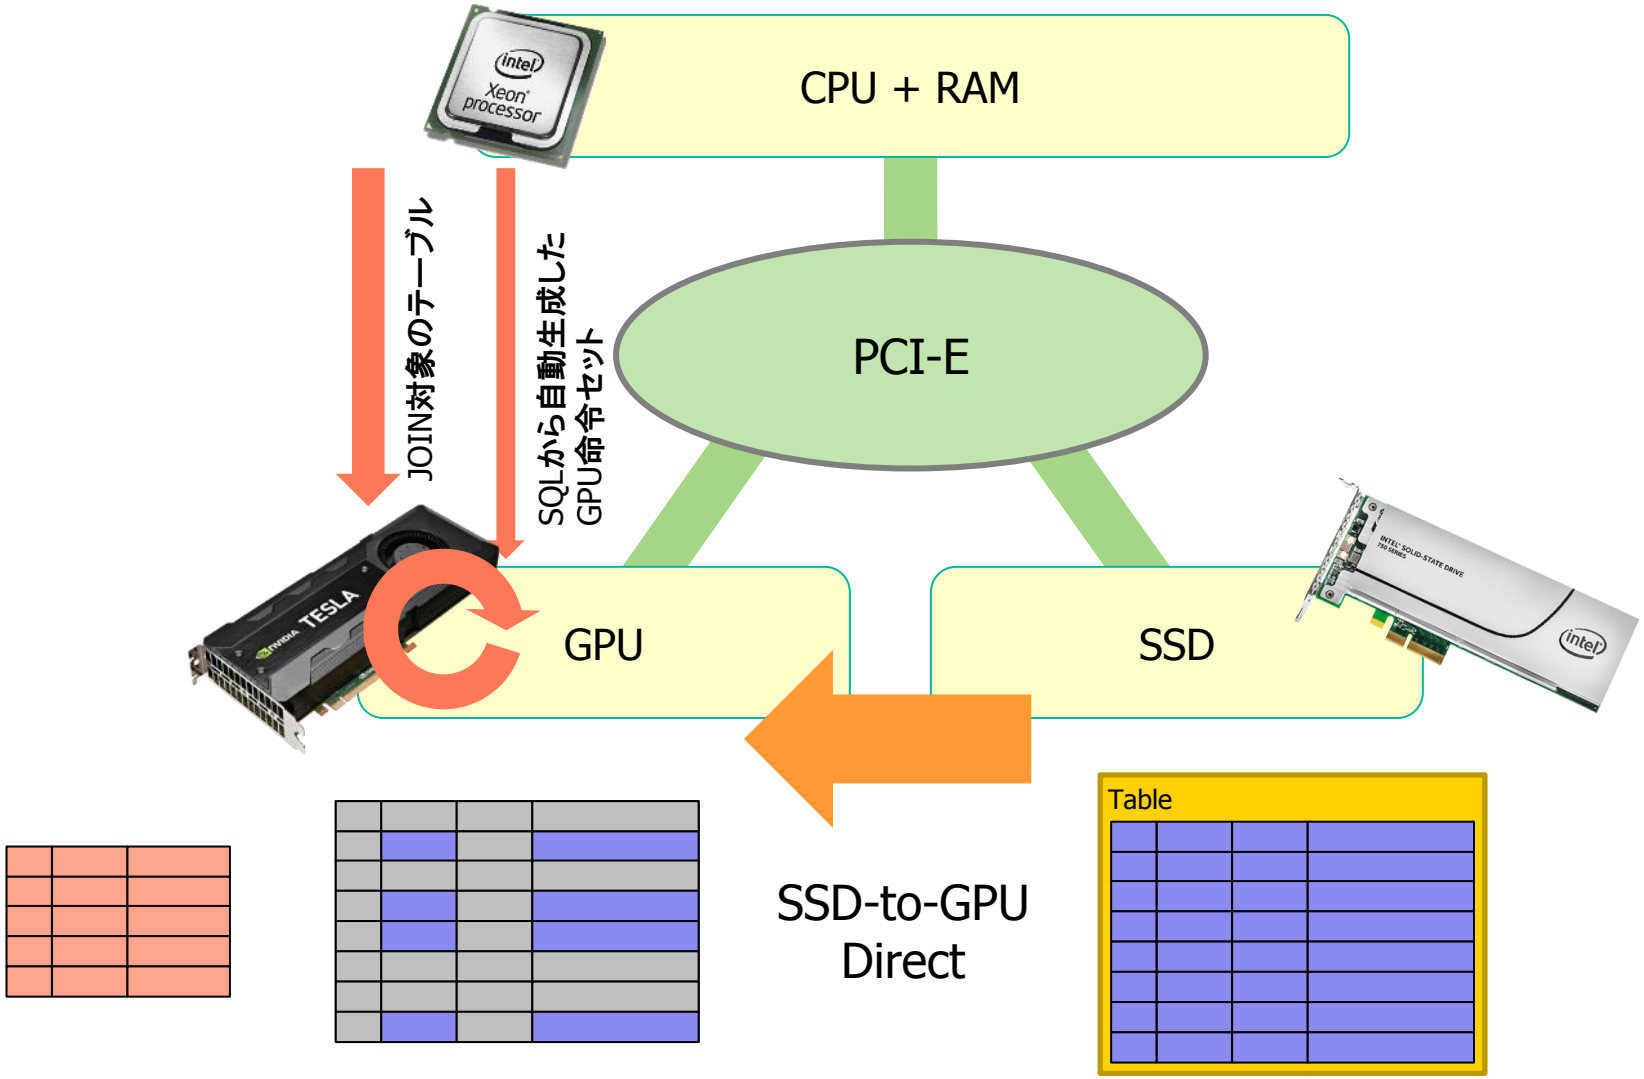

解析系クエリ実行時のデータフロー (3/3) – 鬼アレンジ版

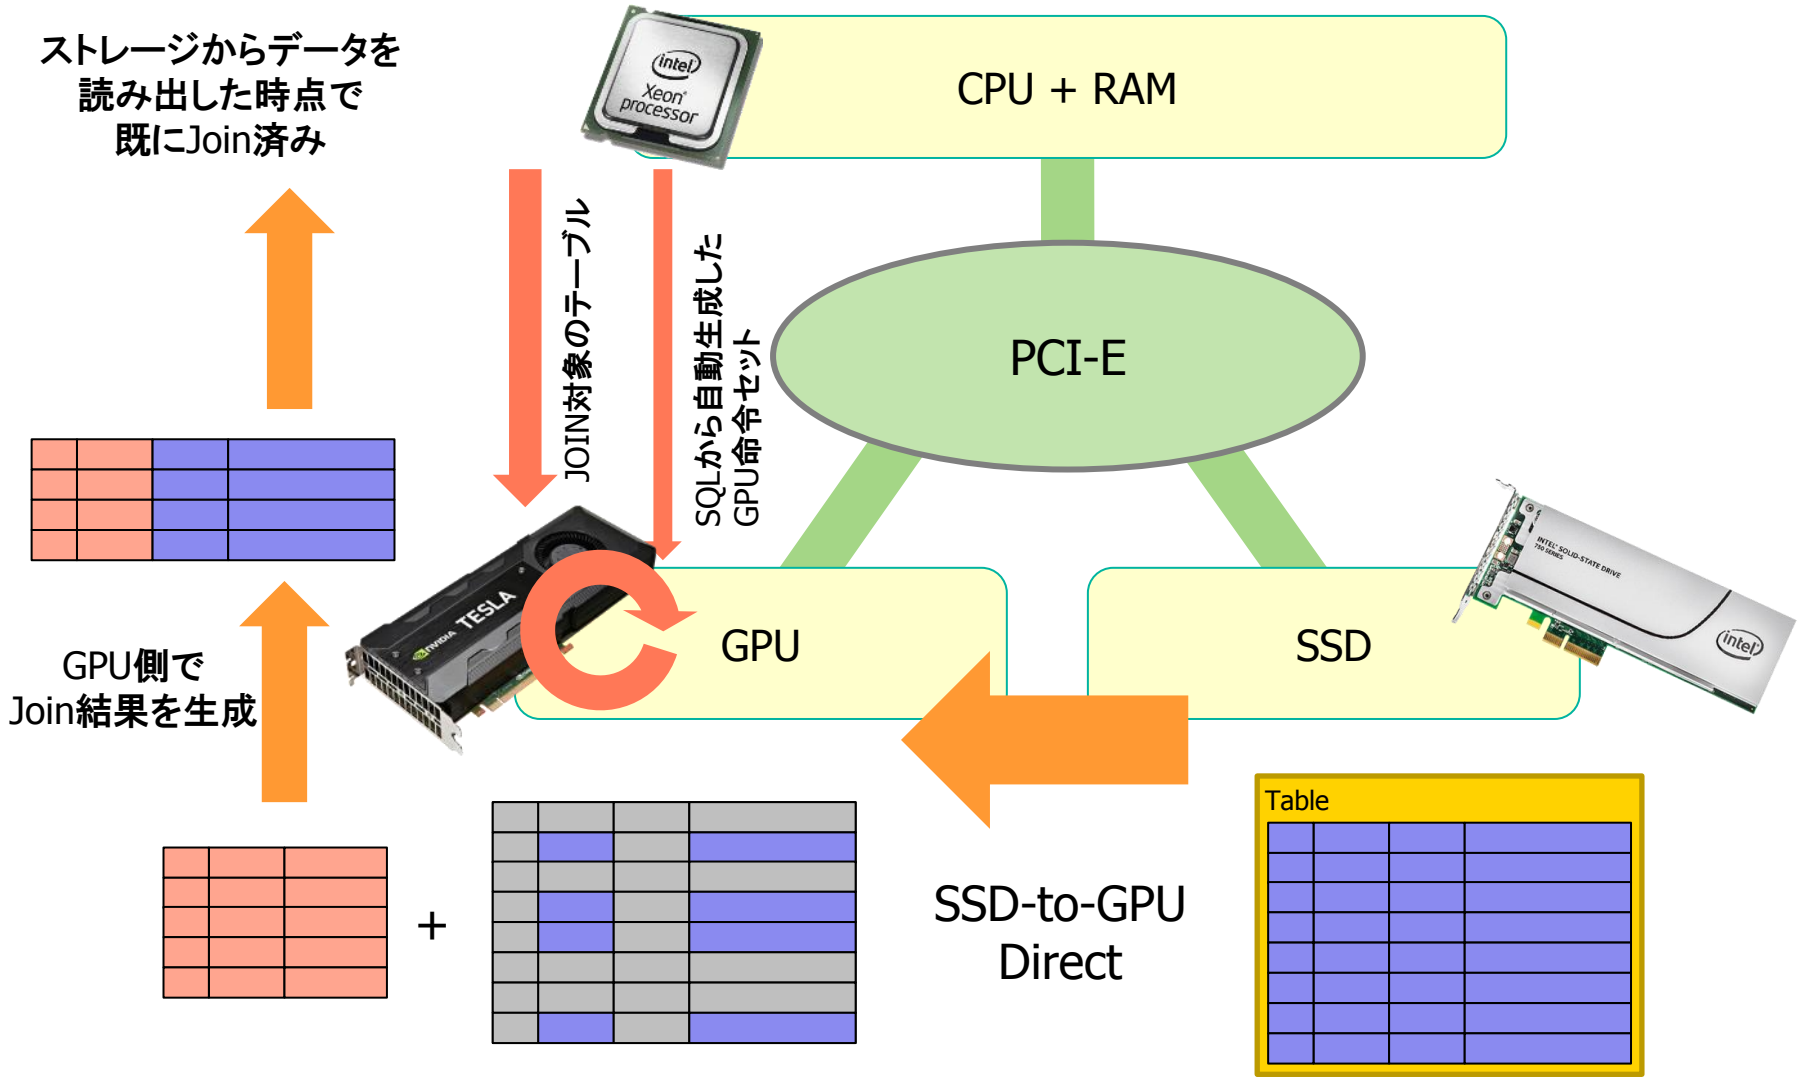

必要な要素技術

NVMeドライバへの NVIDIA GPUDirect 機能の追加

- Linux kernel driverとnvidia driverの間でやり取りが必要…。

shared_bufferの利用率統計情報採取

- テーブルの大半が既にオンメモリなら意味はないので。

shared_bufferのアクセスモード追加

- SSD➔GPU Direct転送が終わるまでは誰も書き込んじゃダメ。

PG-Stromプロジェクトへの参加者熱烈歓迎大募集中

乞うご期待。